

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN CUỐI KỲ
CS313 - KHAI THÁC DỮ LIỆU

HỆ THỐNG CẢNH BÁO SỚM
KẾT QUẢ HỌC TẬP SINH VIÊN
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:
TS. Nguyễn Gia Tuấn Anh

Nhóm Sinh viên:

Họ tên	MSSV
Văn Đức Tân	24521586

Thành phố Hồ Chí Minh, Tháng 5/2026

Mục lục

1	Giới thiệu đề tài	2
1.1	Bối cảnh và động lực	2
1.2	Mục tiêu đề tài	2
1.3	Phạm vi báo cáo	2
1.4	Cấu trúc bộ dữ liệu OULAD	3
2	Khám phá dữ liệu (Exploratory Data Analysis)	4
2.1	Phân tích Null theo ngữ nghĩa (Semantic Null)	4
2.2	Biến mục tiêu (Target Variable)	5
2.3	Kiểm tra cấu trúc Module (Module Structure Audit)	5
2.4	Hiệu ứng Presentation (B vs J)	6
2.5	Phân tích Leakage	6
2.6	Tổng kết EDA	7

1 Giới thiệu đề tài

1.1 Bối cảnh và động lực

Hệ thống học trực tuyến (Virtual Learning Environment — VLE) ngày càng phổ biến, kéo theo nhu cầu phát hiện sớm sinh viên có nguy cơ rớt môn hoặc rút môn để kịp thời can thiệp. Bộ dữ liệu **OULAD** (Open University Learning Analytics Dataset) cung cấp đầy đủ thông tin nhân khẩu học, đăng ký, tương tác VLE và kết quả đánh giá của 32.593 sinh viên trên 7 module học. Đây là dữ liệu lý tưởng để xây dựng mô hình cảnh báo sớm.

1.2 Mục tiêu đề tài

- **Bài toán:** Phân loại 4 nhãn kết quả cuối khóa của sinh viên — *Pass*, *Fail*, *Withdrawn*, *Distinction*.
- **Điểm cắt dự báo:** Sử dụng dữ liệu trong khoảng $[0, 135]$ ngày ($CUTOFF_DAY = 135$) — tương ứng khoảng nửa đầu khóa học — để dự báo kết quả cuối khóa.
- **Ưu tiên:** Tối đa hóa khả năng phát hiện sớm nhóm *Withdrawn* (sinh viên có khả năng bỏ học).
- **Metric chính:** Recall (*Withdrawn*) và Macro-F1 để cân bằng giữa các lớp.

1.3 Phạm vi báo cáo

Báo cáo trình bày toàn bộ pipeline khai thác dữ liệu theo trình tự: khám phá dữ liệu (EDA) → tiền xử lý → feature engineering → huấn luyện và đánh giá mô hình. Phần II tập trung vào EDA — bước nền tảng cho mọi quyết định feature engineering ở các phần sau.

1.4 Cấu trúc bộ dữ liệu OULAD

File	Số dòng	Mô tả
studentInfo.csv	32.593	Thông tin nhân khẩu học sinh viên
studentRegistration.csv	32.593	Ngày đăng ký / rút môn
studentAssessment.csv	173.912	Điểm các bài đánh giá
studentVle.csv	10.655.280	Lượt click trên VLE theo ngày
assessments.csv	206	Metadata bài đánh giá (loại, deadline, weight)
courses.csv	22	Metadata module-presentation
vle.csv	6.364	Metadata tài nguyên VLE

2 Khám phá dữ liệu (Exploratory Data Analysis)

EDA là bước nền tảng quyết định mọi lựa chọn feature engineering ở giai đoạn sau. Mục tiêu phần này gồm 3 trục: (1) hiểu cấu trúc và ngữ nghĩa của null, (2) xác định tín hiệu mạnh trong các nhóm feature, (3) phát hiện các *leakage* tiềm tàng.

2.1 Phân tích Null theo ngữ nghĩa (Semantic Null)

Quan trọng nhất: **null không phải lúc nào cũng là “thiếu dữ liệu”**. Nhiều cột null mang ý nghĩa cụ thể và phải xử lý đúng để giữ được tín hiệu.

Cột	Ý nghĩa thực	Cách xử lý
<code>date_unregistration</code> NULL	Sinh viên không rút môn	Giữ NULL, không <code>dropna()</code>
<code>date_unregistration</code> có giá trị	Sinh viên đã rút môn	Giữ nguyên (nhưng có risk leakage)
<code>score</code> NULL	Sinh viên không nộp bài	<code>fillna(0)</code>
<code>imd_band</code> NULL	Không map được vào vùng UK	Encode "Unknown"
<code>week_from</code> , <code>week_to</code> NULL	Tài nguyên không gắn tuần	Drop 2 cột
<code>date (assessments)</code> NULL	Không biết deadline	Drop khi join

Pattern null score theo `final_result`:

- Withdrawn: $\approx 0.40\%$ null score — cao nhất.
- Fail: $\approx 0.25\%$.
- Pass: $\approx 0.03\%$.
- Distinction: 0.0% .

$\Rightarrow$ `fillna(0)` là semantically correct: không nộp bài = điểm 0, và chính pattern này giúp model học signal phân biệt Withdrawn / Fail vs Pass / Distinction.

2.2 Biến mục tiêu (Target Variable)

2.2.1 Phân phối nhãn

Nhãn	Số lượng	Tỉ lệ
Pass	12.361	37,9%
Withdrawn	10.156	31,2%
Fail	7.052	21,6%
Distinction	3.024	9,3%

⇒ Class imbalance — Distinction chỉ chiếm 9,3%. Cần áp dụng *stratified split* và `class_weight` khi huấn luyện mô hình.

2.2.2 Tín hiệu từ nhóm nhân khẩu học (Demographics)

Feature	Tín hiệu	Ghi chú
num_of_prev_attempts	Mạnh	Càng cao càng rủi ro
highest_education	Trung bình	HE Qualification pass cao nhất
imd_band	Trung bình	90–100% pass tốt hơn rõ rệt
age_band	Trung bình	0–35 Withdrawn nhiều nhất
studied_credits	Yếu	Overlap lớn giữa 4 nhóm
gender	Rất yếu	Gần như không phân biệt M/F

Lưu ý: `studied_credits` là số tín chỉ đăng ký, KHÔNG phải điểm số.

2.3 Kiểm tra cấu trúc Module (Module Structure Audit)

Insight cốt lõi: cấu trúc đánh giá giữa các module khác nhau hoàn toàn. Không thể so sánh raw score cross-module.

Module	CMA	Exam weight	TMA weight	Đặc điểm
AAA	0	200	200	Không có CMA
BBB	15	400	385	Nặng TMA
CCC	8	400	150	CMA tỉ lệ đáng kể
DDD	7	400	375	Nặng TMA
EEE	0	300	300	Không có CMA
FFF	28	400	400	CMA nhiều nhất
GGG	18	300	0	TMA không tính điểm

Hệ quả thiết kế feature:

1. Thêm `code_module` làm categorical feature để mô hình tự học distribution shift theo module.
2. Dùng `weighted_score` thay vì `mean(score)`.
3. Chuẩn hóa submission rate: $\frac{n_submitted}{n_safe_available_in_module}$ thay vì đếm tuyệt đối.
4. Riêng module **GGG** (TMA weight = 0): thêm cờ `has_weighted_score = 0` để model phân biệt.

2.4 Hiệu ứng Presentation (B vs J)

So sánh hai đợt khai giảng (B = February, J = October):

Đợt	Pass rate	<i>n_students</i>
B (Feb)	43,67%	12.488
J (Oct)	— / TODO	— / TODO

⇒ Tính năng `module_semester` (ghép `code_module` _ `code_presentation`) chứa tín hiệu hữu ích — sẽ được mã hóa qua Label Encoding ở phần feature engineering.

2.5 Phân tích Leakage

Các nguồn rò rỉ dữ liệu cần loại bỏ trước khi xây feature:

- `date_unregistration`: biết được sinh viên đã Withdrawn $\Rightarrow$ **drop**.
- Bài thi cuối kỳ (Exam) có `deadline > 135` nhưng correlate 100% với `final_result` $\Rightarrow$ **lọc bỏ** khi tính feature.
- Mọi tương tác VLE với `date > 135` $\Rightarrow$ cắt theo `CUTOFF_DAY`.

2.6 Tổng kết EDA

- Null cần được xử lý theo **ngữ nghĩa**, không phải mặc định `dropna()` hay `mean imputation`.
- Class imbalance nghiêng về Pass, Distinction là lớp thiểu số $\Rightarrow$ cần stratified split và metric Macro-F1.
- Cấu trúc đánh giá khác nhau giữa các module $\Rightarrow$ feature phải được chuẩn hóa relative (rate) thay vì absolute (count).
- Hai nguồn leakage chính: `date_unregistration` và bài thi cuối kỳ $\Rightarrow$ phải loại bỏ trước khi train.

Câu hỏi mở:

- Có nên tách model riêng cho từng nhóm module (AAA/EEE vs GGG vs còn lại) thay vì để `code_module` dạng categorical?
- Pass rate đợt J cụ thể bao nhiêu — cần bổ sung từ notebook.

Tài liệu

- [1] John Doe. Dummy reference, 2026. This is a dummy reference to satisfy BibTeX.