

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN CUỐI KỲ
CS313 - KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

HỆ THỐNG CẢNH BÁO SỚM
KẾT QUẢ HỌC TẬP SINH VIÊN
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:

TS. Võ Nguyễn Lê Duy

Nhóm 11:

Họ tên	MSSV
Nguyễn Đặng Ân Phước	24521408
Phạm Quang Hữu Phước	24521411
Văn Đức Tân	24521586
Liên Phúc Thịnh	24521686
Lê Như Thực	24521747

Thành phố Hồ Chí Minh, Tháng 5/2026

Mục lục

1 Khám phá dữ liệu (Exploratory Data Analysis)	1
1.1 Tổng quan dataset và phân phối biến mục tiêu	1
1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu	1
1.3 Phân tích tín hiệu feature	3
1.4 Kết luận EDA	3
2 Kỹ thuật đặc trưng (Feature Engineering)	4
2.1 Thiết lập chung và Tiền xử lý dữ liệu	4
2.2 Nhóm đặc trưng tĩnh (Static Features)	4
2.3 Nhóm đặc trưng động hàng tuần (Weekly Causal Dynamic Features)	4
2.4 Features Encoding và Out-of-Time (OOT) Split	5
2.5 Định dạng Tensor 3D và Causal Scaling	6
2.6 Phân tích tương quan và Lọc bỏ đặc trưng (Feature Selection)	6
3 Mô hình hóa (Modeling)	8
3.1 Phạm vi thử nghiệm	8
3.2 Mô hình XGBoost và LightGBM	8
3.3 Mô hình LSTM và Transformer	9
3.4 Kết luận	9

1 Khám phá dữ liệu (Exploratory Data Analysis)

1.1 Tổng quan dataset và phân phối biến mục tiêu

OULAD là bộ dữ liệu học tập liên kết gồm 7 bảng quan hệ, bao gồm thông tin của 32.593 lượt đăng ký môn học và hơn 10,6 triệu lượt tương tác trên môi trường học tập ảo (VLE). Biến mục tiêu thể hiện kết quả học tập của người học được chia thành 4 loại `final_result` $\in \{\text{Pass, Withdrawn, Fail, Distinction}\}$.

File	Dòng	Cột có null (%)
studentInfo	32.593	imd_band 3,4%
studentRegistration	32.593	date_unreg 69,1%
studentAssessment	173.912	score 0,1%
studentVle	10.655.280	—
assessments	206	date 5,3%
courses	22	—
vle	6.364	week_from/to 82,4%

Nhãn	Số lượng	Tỉ lệ
Pass	12.361	37,93%
Withdrawn	10.156	31,16%
Fail	7.052	21,64%
Distinction	3.024	9,28%

Trong phạm vi đề án này, nhóm thực hiện chuyển đổi bài toán về dạng **phân loại nhị phân** bằng cách gộp các nhãn mục tiêu ban đầu thành hai nhóm chính:

- **Safe:** Gồm các người học đạt kết quả *Pass* hoặc *Distinction* (nhóm người học an toàn).
- **Not Safe:** Gồm các người học rơi vào trạng thái *Fail* hoặc *Withdrawn* (nhóm người học gặp rủi ro học tập).

Sau khi chuyển đổi, tỷ lệ giữa nhóm Safe ($\sim 47,2\%$) và Not Safe ($\sim 52,8\%$) tương đối cân bằng. Tuy nhiên, nhóm vẫn chọn **Macro-F1** làm độ đo đánh giá chính nhằm đảm bảo mô hình có khả năng phân loại tốt và công bằng trên cả hai nhóm. Điều này giúp tránh tình trạng mô hình dự đoán thiên lệch, từ đó đảm bảo hệ thống cảnh báo sớm đưa ra các quyết định can thiệp đáng tin cậy.

1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu

1.2.1 Phân tích toán tử khuyết mang ngữ nghĩa (Semantic Null)

Một sai lầm phổ biến trong giai đoạn tiền xử lý dữ liệu là việc thực hiện điền giá trị khuyết (`fillna`) hoặc loại bỏ (`dropna`) tất cả các giá trị null một cách máy móc.

Đối với bộ dữ liệu OULAD, các giá trị rỗng không đơn thuần biểu thị sự thiếu hụt dữ liệu (Missing Data), mà ngược lại, mỗi vị trí null đều mang một ngữ nghĩa cụ thể:

Cột	Null %	Ý nghĩa thực	Quyết định
date_unregistration	69,1%	Học đến hết module	Drop (leakage 99,1% Withdrawn)
score	0,1%	Bài không nộp	fillna(0)
imd_band	3,4%	Địa chỉ ngoài UK	Encode "Unknown"
week_from / week_to	82,4%	Resource trải toàn module	Drop cả 2 cột

Cụ thể, thuộc tính date_unregistration có giá trị xuất hiện ở **99,1%** nhóm người học có kết quả *Withdrawn*. Điều này biến đặc trưng này thành một biến đại diện (*proxy*) gần như tuyệt đối cho nhãn mục tiêu, khiến mô hình đối mặt với nguy cơ rò rỉ dữ liệu (*data leakage*) nghiêm trọng. Do đó, việc loại bỏ (*drop*) đặc trưng này là bắt buộc để đảm bảo tính khách quan cho mô hình dự báo.

1.2.2 Chọn cut-off theo data

Median module length 262 ngày. Phân tích phân phối ngày rút môn trên $n = 10.156$ Withdrawn: day 135 (51,6% module) capture $\geq 80\%$ Withdrawn và còn $\sim 48\%$ thời gian can thiệp; day 175 capture $\geq 90\%$ nhưng chỉ còn 33,1% thời gian $\Rightarrow$ quá trễ. Vì pipeline đánh giá trên nhiều mốc cảnh báo, chọn: **cut-off giữa kỳ = 135** (mốc chính, tối ưu coverage vs khả năng can thiệp); **cut-off cuối kỳ = {30, 60, 90, 135}** để theo dõi cách tín hiệu tích lũy theo thời gian khi đánh giá lại ở cuối module.

1.2.3 Kiểm toán leakage tại cut-off 135

Toàn bộ 206 bài đánh giá phân loại SAFE (deadline ≤ 135) vs LEAKAGE (deadline > 135):

Loại	SAFE	LEAK	Median submit ratio	Quyết định
TMA	71	35	0,353	Dùng (đa số SAFE)
CMA	17	59	0,577	Chuẩn hóa theo từng module
Exam	0	6	0,927	Drop hoàn toàn

Median submit ratio Exam (0,927) $\Rightarrow$ bài thi luôn ở cuối kỳ, không có bài SAFE nào tại day 135, drop. CMA có 17/76 SAFE phân bố không đều giữa modules (AAA, EEE không có CMA) $\Rightarrow$ FE chuẩn hoá thành cma_submission_rate.

1.3 Phân tích tín hiệu feature

1.3.1 Tín hiệu nhân khẩu học

Chi-square test ($n = 32.593$) trên các biến categorical so với nhãn `final_result`:

Feature	χ^2	Signal
<code>code_module</code>	1443,2	Rất mạnh
<code>highest_education</code>	1024,7	Rất mạnh
<code>imd_band</code>	666,9	Rất mạnh
<code>region</code>	449,7	Mạnh
<code>age_band</code>	222,7	Mạnh
<code>disability</code>	138,5	Trung bình
<code>gender</code>	16,5	Rất yếu $\rightarrow$ drop

`gender` có χ^2 thấp hơn `code_module` gần **90 lần** $\Rightarrow$ drop. 4 biến mạnh được giữ và encode ordinal để bảo toàn quan hệ monotonic cho tree-based model.

1.3.2 Hiệu ứng kỳ học (Semester B vs J)

Pass rate kỳ B (tháng 2) = 43,67% ($n = 12.488$), kỳ J (tháng 10) = 49,40% ($n = 20.105$). Chênh lệch không đồng đều theo module: CCC diff = $-6,38$ pp, EEE diff = $-6,28$ pp (vượt ngưỡng ± 5 pp) $\Rightarrow$ semester **phải là feature**, không lọc bỏ.

1.4 Kết luận EDA

EDA xác định các nhóm tín hiệu khả dụng tại cut-off 135: (i) nhân khẩu học (4 biến sau chi-square), (ii) điểm có trọng số trước cut-off (TMA SAFE 71/106), (iii) hành vi nộp bài (submission rate, deadline gap). Tín hiệu hành vi VLE sẽ phân tích chi tiết ở giai đoạn Feature Engineering sau khi thống nhất pipeline nhị phân (At-Risk vs Not At-Risk).

2 Kỹ thuật đặc trưng (Feature Engineering)

2.1 Thiết lập chung và Tiền xử lý dữ liệu

Dữ liệu được tái cấu trúc thành dạng chuỗi tuần (*weekly panel*) cho mô hình LSTM và Transformer với các thiết lập:

- **Mốc cắt (*Cut-off Day*):** Ngày **170** của học kỳ, tương ứng tối đa **25 tuần** học ($T_{MAX} = 25$, độ dài tuần 7 ngày). Các tương tác và điểm số sau ngày 170 bị loại bỏ.
- **Nhãn mục tiêu:**
 - Nguy cơ (Fail/Withdrawn): Gán 1.
 - An toàn (Pass/Distinction): Gán 0.

Quy trình làm sạch dữ liệu thô bao gồm:

- `date_registration`: Trung vị theo đợt học (*module-presentation*).
- `imd_band`, `age_band`: “Unknown”.
- `score` (khuyết): 0.
- `date_unregistration`, `week_from`, `week_to`: Loại bỏ hoàn toàn.

2.2 Nhóm đặc trưng tĩnh (Static Features)

Đặc trưng tĩnh là thông tin cố định, được truyền vào mô hình tại mọi bước thời gian:

- **Nhân khẩu học:** `gender`, `age_band`, `imd_band`, `region`, `highest_education`, `disability`, `studied_credits` và `num_of_prev_attempts`.
- **Bối cảnh học tập:** `date_registration`, `code_module`, `code_presentation`, `module_semester` và `semester`.
- **Tương tác trước khóa học** ($date < 0$): `pre_course_clicks`, `pre_course_active_days` và `has_pre_course_activity`.

2.3 Nhóm đặc trưng động hàng tuần (Weekly Causal Dynamic Features)

Đặc trưng tại tuần t chỉ được tổng hợp từ dữ liệu phát sinh từ ngày 0 đến $7(t+1) - 1$ để đảm bảo tính nhân quả. Quy trình trích xuất gồm hai nhóm:

1. Đặc trưng động theo tuần (Weekly Features):

- **Tương tác VLE trong tuần học t :** `clicks_this_week` (tổng click), `active_days_this_week` (ngày hoạt động), thống kê click ngày (`max_daily_clicks_week`, `median_daily_clicks_week`, `std_clicks_week`),

click ngày cuối tuần (`weekend_clicks_week`) và lượng tương tác theo 6 tài nguyên chính (`oucontent`, `forumng`, `homepage`, `subpage`, `url`, `quiz`).

- **Kết quả đánh giá trong tuần học t :** Số bài đánh giá đã nộp, tổng điểm nhận được, tổng trọng số, tổng điểm có trọng số tương ứng và số ngày nộp trước hạn trung bình trong tuần. Đồng thời so sánh số bài TMA và CMA thực tế đã nộp với số bài đến hạn (**due deadline**) trong tuần t .

2. Đặc trưng động nhân quả (Causal Dynamic Features):

- **Tương tác VLE:**
 - `cum_clicks`: Tổng click.
 - `cum_active_days`: Số ngày tương tác.
 - `active_rate_so_far`: Tỷ lệ ngày hoạt động.
 - `clicks_per_active_day_cum`: Click trung bình mỗi ngày hoạt động.
 - `days_since_last_active`: Số ngày từ lần tương tác cuối.
 - `active_span_so_far`: Khoảng thời gian hoạt động.
- **Xu hướng tương tác và khoảng trống:**
 - `click_slope_recent`, `click_slope_r2_recent`: Hệ số góc và hệ số xác định trên 4 tuần gần nhất $[t-3, t]$.
 - `activity_density_so_far`: Mật độ ngày hoạt động.
 - `gap_std_so_far`, `gap_trend_so_far`: Độ lệch chuẩn và xu hướng khoảng cách giữa các ngày hoạt động liên tiếp.
 - `ratio_{type}_so_far`: Tỷ lệ click theo tài nguyên.
 - `weekend_ratio_so_far`: Tỷ lệ click cuối tuần.
- **Kết quả học tập:**
 - `mean_score_so_far`: Điểm trung bình.
 - `weighted_score_so_far`: Điểm trọng số.
 - `tma_submission_rate_so_far`, `cma_submission_rate_so_far`: Tỷ lệ nộp bài TMA và CMA.
 - `n_missing_so_far`: Số bài đánh giá bỏ lỡ.

2.4 Features Encoding và Out-of-Time (OOT) Split

Phương pháp mã hóa các đặc trưng gồm:

- **Ordinal Encoding:** Áp dụng cho các biến thứ bậc gồm `highest_education_encoded`, `age_band_encoded` và `imd_band_encoded`.
- **Binary Encoding:** Dành cho `semester_enc`, `gender_encoded`, `disability_encoded` và đợt học `module_semester_encoded`.
- **One-hot Encoding:** Chuyển đổi vùng địa lý `region` thành 12 biến giả nhị phân. Tập dữ liệu thô ban đầu gồm 33 đặc trưng động và 25 đặc trưng tĩnh.

Chiến lược phân chia Out-of-Time (OOT) theo kỳ học thực tế:

- **Tập Train (21.333 lượt học):** Gồm dữ liệu sinh viên thuộc các kỳ học cũ (2013B, 2013J, 2014B).
- **Tập Test (11.260 lượt học):** Gồm dữ liệu sinh viên thuộc kỳ học cuối cùng (2014J).

Sau khi phân chia Train/Test theo kỳ học thực tế, dữ liệu được kết xuất dưới ba định dạng chính để phục vụ huấn luyện các thuật toán học máy khác nhau:

- **Định dạng dài (LONG Format - `df_train_long.csv`, `df_test_long.csv`):** Dạng bảng tuần (*panel data*) với mỗi lượt học của sinh viên gồm đúng 25 hàng tương ứng với 25 timestep tuần học học tập (từ tuần 0 đến tuần 24), phục vụ tốt nhất cho các mô hình học sâu chuỗi thời gian như LSTM hay Transformer.
- **Định dạng rộng (WIDE Format - `df_train.csv`, `df_test.csv`):** Dữ liệu phẳng được trích xuất bằng cách lấy snapshot tại tuần cuối cùng của kỳ học trước mốc cutoff ($T = 24$), thu gọn chuỗi đặc trưng thành một dòng duy nhất cho mỗi học viên, đặc biệt thích hợp cho huấn luyện so sánh hoặc dự đoán nhanh qua các mô hình học máy truyền thống như XGBoost hay LightGBM.
- **Định dạng mảng (TENSOR Format - các file `.npy`):** Lưu trữ các mảng numpy 3D và 2D đã được chuẩn hóa sâu (`X_seq_train.npy`, `X_static_train.npy`, `y_train.npy`, v.v.) để tăng tốc độ nạp dữ liệu trực tiếp vào mô hình PyTorch trong suốt quá trình train.

2.5 Định dạng Tensor 3D và Causal Scaling

Các đặc trưng được tổng hợp thành cấu trúc Tensor trong PyTorch để huấn luyện:

- **`X_seq`:** Kích thước $(N, T_{MAX}, 33)$, với N là số lượt học, $T_{MAX} = 25$ tuần, và 33 đặc trưng động tại mỗi timestep.
- **`X_static`:** Kích thước $(N, 25)$ đặc trưng tĩnh.
- **`mask`:** Kích thước (N, T_{MAX}) kiểu nhị phân dùng để che phủ (*padding*) phục vụ chiến lược Random-Truncation Training.
- **`y`:** Kích thước (N) lưu trữ nhãn thực tế.

Chuẩn hóa dữ liệu bằng `StandardScaler` tránh rò rỉ thông tin từ tập Test vào tập Train.

2.6 Phân tích tương quan và Lọc bỏ đặc trưng (Feature Selection)

Quy trình lọc bỏ đặc trưng:

- **Kiểm định tương quan Pearson:** Tính toán tương quan giữa từng đặc trưng số động với nhãn mục tiêu tại tuần cuối cùng ($T = 24$), giữ lại các đặc trưng có $|corr| \geq 0,03$.

- **Kiểm định Chi-square (χ^2):** Loại bỏ các đặc trưng có mức ý nghĩa p -value $> 0,05$.

Kết quả của quá trình lọc chọn đặc trưng:

- **Dynamic Features:** Loại bỏ **9 đặc trưng**: `active_rate_so_far`, `active_days_this_week`, `max_daily_clicks_week`, `median_daily_clicks_week`, `n_missing_so_far`, `active_span_so_far`, `cum_clicks`, `weighted_score_so_far`, `std_clicks_week`.
- **Static Features:** Loại bỏ **11 đặc trưng**: `highest_education_encoded`, `imd_band_encoded`, `module_semester_encoded` và 8 biến giả khu vực địa lý.

Mô hình LSTM và Transformer cuối cùng sẽ chỉ tiếp nhận chuỗi Tensor `X_seq` gồm 24 đặc trưng động và Tensor tĩnh `X_static` gồm 14 đặc trưng tĩnh đã được tinh lọc.

3 Mô hình hóa (Modeling)

3.1 Phạm vi thử nghiệm

Phần modeling trong đề án được thực hiện trên hai nhánh khác nhau: nhánh mô hình học máy truyền thống và nhánh mô hình chuỗi. Các mô hình được đánh giá theo nhiều mốc thời gian để phản ánh đúng bài toán cảnh báo sớm. Với nhánh ML, nhóm sử dụng các snapshot tuần 4, 8, 12, 16, 20 và 24. Với nhánh sequence, mô hình được đánh giá liên tục theo từng tuần, từ giai đoạn đầu khóa học đến cuối khóa học. Các metric chính gồm AUC-ROC, Accuracy, Precision, Recall và F1-score.

3.2 Mô hình XGBoost và LightGBM

Trong nhánh ML truyền thống, nhóm huấn luyện hai mô hình tree boosting là **XGBoost** và **LightGBM** cho từng snapshot tuần. Mỗi snapshot chỉ sử dụng thông tin đã có tới thời điểm tương ứng, nhờ đó mô phỏng được tình huống hệ thống cảnh báo được cập nhật định kỳ trong quá trình học.

Kết quả LightGBM

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8221	0,7397	0,7428	0,7570	0,7499
8	0,8738	0,7811	0,8583	0,6890	0,7644
12	0,8870	0,7981	0,8135	0,7892	0,8012
16	0,9263	0,8518	0,9169	0,7834	0,8449
20	0,9441	0,8774	0,9200	0,8347	0,8753
24	0,9626	0,9015	0,9372	0,8670	0,9007

Kết quả XGBoost

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8266	0,7263	0,6948	0,8363	0,7590
8	0,8775	0,7829	0,8592	0,6921	0,7666
12	0,8826	0,7893	0,7934	0,7994	0,7964
16	0,9295	0,8485	0,9211	0,7722	0,8401
20	0,9454	0,8778	0,9259	0,8292	0,8749
24	0,9624	0,9012	0,9391	0,8642	0,9001

Kết quả cho thấy cả hai mô hình đều cải thiện rõ khi có thêm dữ liệu theo thời gian. Ở tuần 4, mô hình đã đạt F1 khoảng 0,75, cho thấy các tín hiệu ban đầu đủ mạnh để phát cảnh báo sớm. Đến tuần 24, F1 đạt khoảng 0,90 và AUC vượt 0,96.

3.3 Mô hình LSTM và Transformer

Nhánh sequence sử dụng dữ liệu dạng chuỗi theo tuần để huấn luyện mô hình **LSTM** và **Transformer**. Mô hình nhận hai nhóm đầu vào: đặc trưng động theo thời gian và đặc trưng tĩnh của sinh viên.

Kết quả LSTM

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8147	0,7352	0,8106	0,6343	0,7117
8	0,8790	0,7884	0,8864	0,6760	0,7670
12	0,8969	0,8171	0,8866	0,7398	0,8066
16	0,9311	0,8571	0,9338	0,7779	0,8487
20	0,9472	0,8800	0,9616	0,7991	0,8728
24	0,9639	0,9023	0,9659	0,8401	0,8986
33	0,9808	0,9329	0,9752	0,8926	0,9321

Kết quả Transformer

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8277	0,7481	0,7805	0,7114	0,7443
8	0,8791	0,7923	0,8663	0,7058	0,7779
12	0,8963	0,8099	0,8490	0,7675	0,8062
16	0,9288	0,8552	0,8867	0,8244	0,8544
20	0,9430	0,8763	0,9214	0,8308	0,8738
24	0,9629	0,8996	0,9202	0,8818	0,9006
33	0,9775	0,9295	0,9742	0,8866	0,9284

LSTM và Transformer thể hiện xu hướng tăng ổn định theo số tuần quan sát. Ở tuần 12, F1 đạt 0,8; đến tuần 24 đạt 0,9; và ở tuần 33 đạt 0,93. Điều này cho thấy mô hình khai thác tốt thông tin tích lũy dài hạn trong chuỗi hành vi học tập.

3.4 Kết luận

Ở các tuần 20–24, cả mô hình ML theo snapshot và mô hình sequence đều đạt F1 xấp xỉ 0,87–0,90, cho thấy hệ thống đã có thể đưa ra cảnh báo tương đối tin cậy trước khi kết thúc khóa học. Các mô hình đã sẵn sàng để được đóng gói và triển khai trên ứng dụng thực tế.