

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN CUỐI KỲ
CS313 - KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

HỆ THỐNG CẢNH BÁO SỚM
KẾT QUẢ HỌC TẬP SINH VIÊN
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:
Võ Nguyễn Lê Duy

Nhóm 11:

Họ tên	MSSV
Nguyễn Đặng Ân Phước	24521408
Phạm Quang Hữu Phước	24521411
Văn Đức Tân	24521586
Liên Phúc Thịnh	24521686
Lê Như Thực	24521747

Thành phố Hồ Chí Minh, Tháng 5/2026

Mục lục

1 Khám phá dữ liệu (Exploratory Data Analysis)	2
1.1 Tổng quan dataset và biến mục tiêu	2
1.2 Xử lý null và tín hiệu nhân khẩu học	2
1.3 Kiểm toán cấu trúc học phần và kỳ học	3
1.4 Pattern hành vi, chọn cut-off và rò rỉ dữ liệu	4
1.5 Kết luận EDA	4

1 Khám phá dữ liệu (Exploratory Data Analysis)

1.1 Tổng quan dataset và biến mục tiêu

OULAD gồm 7 bảng quan hệ; bài toán đặt ra là phân loại 4 nhãn `final_result` của 32.593 sinh viên dựa trên dữ liệu trong $[0, 135]$ ngày đầu ($\text{cut-off} = 135$, xem mục 1.4).

File	Số dòng	Mô tả
<code>studentInfo.csv</code>	32.593	Nhân khẩu học sinh viên
<code>studentRegistration.csv</code>	32.593	Ngày đăng ký / rút môn
<code>studentAssessment.csv</code>	173.912	Điểm các bài đánh giá
<code>studentVle.csv</code>	10.655.280	Lượt click VLE theo ngày
<code>assessments.csv</code>	206	Loại bài, deadline, weight
<code>courses.csv</code>	22	Metadata module— presentation
<code>vle.csv</code>	6.364	Metadata tài nguyên VLE

Nhãn	Số lượng	Tỉ lệ
Pass	12.361	37,93%
Withdrawn	10.156	31,16%
Fail	7.052	21,64%
Distinction	3.024	9,28%

Distinction chỉ 9,28% $\Rightarrow$ dùng *stratified split* và chọn **Macro-F1** làm metric chính.

1.2 Xử lý null và tín hiệu nhân khẩu học

Null mang ngữ nghĩa, không phải thiếu dữ liệu: `date_unregistration` NULL nghĩa là sinh viên *không rút môn* (giữ NULL); `score` NULL nghĩa là *không nộp bài* $\Rightarrow$ `fillna(0)` — chính pattern này tự là tín hiệu phân biệt Withdrawn/Fail với Pass/Distinction.

Notebook EDA (Section 10) chạy Chi-square trên 8 biến categorical so với `final_result`, output $\text{Chi}^2 + p\text{-value}$ như sau (rank theo Chi^2 giảm dần):

Feature	Chi ²	<i>p</i> -value	Pipeline (FE Cell 31)
code_module	1443,2	$7,6 \times 10^{-296}$	Giữ (categorical)
highest_education	1024,7	$9,2 \times 10^{-212}$	Giữ (ordinal)
imd_band	666,9	$3,2 \times 10^{-123}$	Giữ (ordinal)
region	449,7	$6,5 \times 10^{-73}$	Giữ (one-hot 12 vùng)
code_presentation	402,2	$4,7 \times 10^{-81}$	Gộp module_semester
age_band	222,7	$2,8 \times 10^{-45}$	Giữ (ordinal)
disability	138,5	$8,1 \times 10^{-30}$	<i>Drop</i>
gender	16,5	$8,8 \times 10^{-04}$	<i>Drop</i>

Với $n = 32.593$, mọi p -value đều $< 0,001$ nên label "*Mạnh*" trong notebook không phân biệt được biến nào thực sự quan trọng. Dùng Chi² tuyệt đối để xếp hạng: **gender** thấp hơn biến đứng đầu gần 90 lần. Numeric features (**num_of_prev_attempts**, **studied_credits**) được xét qua Spearman trong cùng cell và qua **mutual_info_classif** ở FE Cell 28 (vẫn được giữ nguyên). Quyết định cuối ở FE Cell 31: **redundant_features** gồm **gender_encoded** và **disability_encoded** (Chi² nhỏ nhất). Các biến giữ được encode theo **ordinal** (FE Cell 27): No Formal qual $\rightarrow 0$, ..., Post Graduate Qualification $\rightarrow 4$; 0-10% $\rightarrow 0$, ..., 90-100% $\rightarrow 9$, Unknown $\rightarrow 10$ — giữ quan hệ monotonic cho tree-based model.

1.3 Kiểm toán cấu trúc học phần và kỳ học

Insight: trọng số và số lượng bài đánh giá giữa 7 module chênh lệch rất lớn $\Rightarrow$ **không thể so sánh raw score cross-module**. Bảng dưới trích 3 module đại diện cho 3 cực:

Module	CMA	Exam w.	TMA w.	Đặc điểm
AAA	0	200	200	Không có CMA
FFF	28	400	400	Nhiều CMA nhất
GGG	18	300	0	TMA không tính điểm


Tương tự, hai đợt khai giảng chênh pass rate đáng kể: B (tháng 2) 43,67%, J (tháng 10) 49,40% — chênh ~ 6 pp và không đồng đều giữa modules.

$\Rightarrow$ FE thêm **code_module** categorical, dùng **weighted_score** thay raw mean, cờ **has_weighted_score** cho GGG, và mã hoá **module_semester** (interaction **code_module** $\times$ **semester**).

1.4 Pattern hành vi, chọn cut-off và rò rỉ dữ liệu

Điểm có trọng số (Figure 1, trái) là tín hiệu mạnh nhất tại cut-off 135: median Distinction 89, 3, Pass 76, 7, Fail 64, 0, Withdrawn 66, 0. Đáng chú ý median Withdrawn không thấp như kỳ vọng — *nhiều sinh viên rút môn không phải vì điểm kém* (lý do cá nhân); IQR Withdrawn rộng (0–80) $\Rightarrow$ cần thêm tín hiệu hành vi để phân loại.

Thời điểm rút môn (Figure 1, phải): trong 10.063 Withdrawn có `date_unregistration`, $\sim 50\%$ **rút trong 30 ngày đầu** (phase A+B) — củng cố giá trị của các temporal features (clicks tuần đầu, vùng zero-click trước khi rút).



Hình 1: Trái: phân phối `weighted_score` theo `final_result`. Phải: thời điểm rút môn của Withdrawn theo 4 phase A/B/C/D.

Cut-off 135 ngày chọn theo data-driven: median module length là 262 ngày; day 135 (51,6% độ dài) là điểm nhỏ nhất capture $\geq 80\%$ Withdrawn, vẫn còn $\sim 48\%$ thời gian can thiệp. Ba nguồn leakage phải loại:

- `date_unregistration` có giá trị trong 99,1% ca Withdrawn — proxy của label $\Rightarrow$ **drop**.
- Exam (6 bài, deadline đều > 135) tương quan $\sim 100\%$ với `final_result` $\Rightarrow$ **không dùng**.
- Mọi tương tác VLE/assessment có `date` sau cut-off $\Rightarrow$ cắt; với CMA chỉ còn 17/76 bài *safe*, FE chuẩn hoá thành tỉ lệ (`cma_submission_rate`) thay vì đếm tuyệt đối.

1.5 Kết luận EDA

EDA xác định 4 nhóm tín hiệu khả dụng tại cut-off 135 ngày: (i) nhân khẩu (3 biến), (ii) điểm có trọng số trước cut-off, (iii) hành vi VLE theo thời gian, (iv) hành vi nộp bài. Chương sau xây dựng feature engineering bám sát 4 nhóm này, loại bỏ leakage và chuẩn hoá theo module.

Tài liệu

- [1] John Doe. Dummy reference, 2026. This is a dummy reference to satisfy BibTeX.