

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH  
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN CUỐI KỲ  
CS313 - KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

HỆ THỐNG CẢNH BÁO SỚM  
KẾT QUẢ HỌC TẬP SINH VIÊN  
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:  
Võ Nguyễn Lê Duy

Nhóm 11:

| Họ tên               | MSSV     |
|----------------------|----------|
| Nguyễn Đặng Ân Phước | 24521408 |
| Phạm Quang Hữu Phước | 24521411 |
| Văn Đức Tân          | 24521586 |
| Liên Phúc Thịnh      | 24521686 |
| Lê Như Thực          | 24521747 |

Thành phố Hồ Chí Minh, Tháng 5/2026

# Mục lục

|                                                                 |          |
|-----------------------------------------------------------------|----------|
| <b>1 Khám phá dữ liệu (Exploratory Data Analysis)</b>           | <b>2</b> |
| 1.1 Tổng quan dataset và phân phối biến mục tiêu . . . . .      | 2        |
| 1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu . . . . | 2        |
| 1.3 Phân tích tín hiệu feature . . . . .                        | 3        |

# 1 Khám phá dữ liệu (Exploratory Data Analysis)

## 1.1 Tổng quan dataset và phân phối biến mục tiêu

OULAD gồm 7 bảng quan hệ, phủ 32.593 lượt đăng ký học phần với 10.655.280 lượt tương tác VLE. Bài toán phân loại 4 nhãn `final_result`  $\in \{\text{Pass, Withdrawn, Fail, Distinction}\}$ .

| File                             | Dòng       | Cột có null (%)                 |
|----------------------------------|------------|---------------------------------|
| <code>studentInfo</code>         | 32.593     | <code>imd_band</code> 3,4%      |
| <code>studentRegistration</code> | 32.593     | <code>date_unreg</code> 69,1%   |
| <code>studentAssessment</code>   | 173.912    | <code>score</code> 0,1%         |
| <code>studentVle</code>          | 10.655.280 | —                               |
| <code>assessments</code>         | 206        | <code>date</code> 5,3%          |
| <code>courses</code>             | 22         | —                               |
| <code>vle</code>                 | 6.364      | <code>week_from/to</code> 82,4% |

| Nhãn        | Số lượng | Tỉ lệ  |
|-------------|----------|--------|
| Pass        | 12.361   | 37,93% |
| Withdrawn   | 10.156   | 31,16% |
| Fail        | 7.052    | 21,64% |
| Distinction | 3.024    | 9,28%  |

Distinction chiếm 9,28% — class nhỏ nhất, ít hơn Pass  $\sim 4$  lần  $\Rightarrow$  chọn **Macro-F1** làm metric chính để không bỏ qua class thiểu số.

## 1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu

### 2.1 Semantic Null — null không phải thiếu data

Sai lầm phổ biến là `fillna/drop` tất cả null cơ học. Trong OULAD mỗi null đều mang ngữ nghĩa cụ thể:

| Cột                              | Null % | Ý nghĩa thực              | Quyết định                               |
|----------------------------------|--------|---------------------------|------------------------------------------|
| <code>date_unregistration</code> | 69,1%  | NULL = học đến hết module | Giữ; <b>drop khỏi features</b> (leakage) |
| <code>score</code>               | 0,1%   | Bài không nộp             | <code>fillna(0)</code>                   |
| <code>imd_band</code>            | 3,4%   | Địa chỉ ngoài UK          | Encode "Unknown"                         |
| <code>week_from / week_to</code> | 82,4%  | Resource trải toàn module | Drop cả 2 cột                            |

`date_unregistration` có giá trị ở **99,1%** ca Withdrawn  $\Rightarrow$  proxy gần tuyệt đối của label, bắt buộc drop để tránh leakage 100%. Ngược lại, NULL ở 69,1% còn lại là tín hiệu *positive* (sinh viên tiếp tục học).

## 2.2 Chọn cut-off theo data

Median module length 262 ngày. Phân tích phân phối ngày rút môn trên  $n = 10.156$  Withdrawn: day 135 (51,6% module) capture  $\geq 80\%$  Withdrawn và còn  $\sim 48\%$  thời gian can thiệp; day 175 capture  $\geq 90\%$  nhưng chỉ còn 33,1% thời gian  $\Rightarrow$  quá trễ. Chọn **CUTOFF\_DAY = 135** — cân bằng tối ưu giữa coverage và khả năng can thiệp.

## 2.3 Kiểm toán leakage tại cut-off 135

Toàn bộ 206 bài đánh giá phân loại SAFE (`deadline`  $\leq 135$ ) vs LEAK-AGE (`deadline`  $> 135$ ):

| Loại | SAFE      | LEAK      | Median submit ratio | Quyết định                   |
|------|-----------|-----------|---------------------|------------------------------|
| TMA  | <b>71</b> | 35        | 0,353               | ✓ Dừng (đa số SAFE)          |
| CMA  | 17        | <b>59</b> | 0,577               | ✓ Chuẩn hóa theo từng module |
| Exam | 0         | <b>6</b>  | 0,927               | × Drop hoàn toàn             |

Median submit ratio Exam (0,927)  $\Rightarrow$  bài thi luôn ở cuối kỳ, không có bài SAFE nào tại day 135, drop. CMA có 17/76 SAFE phân bố không đều giữa modules (AAA, EEE không có CMA)  $\Rightarrow$  FE chuẩn hoá thành `cma_submission_rate`.

## 1.3 Phân tích tín hiệu feature

### 3.1 Tín hiệu nhân khẩu học

Chi-square test ( $n = 32.593$ ) trên các biến categorical so với nhãn `final_result`:

| Feature                        | $\chi^2$ | Signal                            |
|--------------------------------|----------|-----------------------------------|
| <code>code_module</code>       | 1443,2   | <b>Rất mạnh</b>                   |
| <code>highest_education</code> | 1024,7   | <b>Rất mạnh</b>                   |
| <code>imd_band</code>          | 666,9    | <b>Rất mạnh</b>                   |
| <code>region</code>            | 449,7    | Mạnh                              |
| <code>age_band</code>          | 222,7    | Mạnh                              |
| <code>disability</code>        | 138,5    | Trung bình                        |
| <code>gender</code>            | 16,5     | <b>Rất yếu</b> $\rightarrow$ drop |

`gender` có  $\chi^2$  thấp hơn `code_module` gần **90 lần**  $\Rightarrow$  drop. 4 biến mạnh được giữ và encode ordinal để bảo toàn quan hệ monotonic cho tree-based model.

### 3.2 Hiệu ứng kỳ học (Semester B vs J)

Pass rate kỳ B (tháng 2) = 43,67% ( $n = 12.488$ ), kỳ J (tháng 10) = 49,40% ( $n = 20.105$ ). Chênh lệch không đồng đều theo module: CCC diff =  $-6,38$  pp, EEE diff =  $-6,28$  pp (vượt ngưỡng  $\pm 5$  pp)  $\Rightarrow$  semester **phải là feature**, không lọc bỏ.

### 3.3 Tín hiệu hành vi VLE

Phân tích 10.655.280 dòng `studentVle.csv` (log click của sinh viên trên hệ thống học trực tuyến) trong khoảng ngày  $[-\infty, 135]$  phát hiện 3 pattern chính:

- **Pre-course** (click trước ngày khai giảng, `date` < 0): tương quan Spearman với nhãn rất rõ —  $\rho_{\text{pre\_clicks}} = +0,2684$ ,  $\rho_{\text{pre\_days}} = +0,2471$  ( $p \approx 0$ ).  $\Rightarrow$  sinh viên *xem trước tài liệu* đã là tín hiệu cảnh báo sớm.
- **Activity ratio** (tỉ lệ click Distinction / Withdrawn theo loại tài nguyên): forum  $4,65\times$ , nội dung học  $4,09\times$ , quiz  $1,44\times$ .  $\Rightarrow$  Withdrawn gần như *không vào forum*, khác biệt mạnh nhất ở forum và nội dung.
- **Temporal** (phân phối click theo thời gian): Withdrawn có peak sớm (ngày 0–30) rồi biến mất; Pass/Distinction click đều đặn đến cuối.  $\Rightarrow$  tổng click (`sum_click`) kém phân biệt; FE cần các feature thời gian: số ngày active, ngày active cuối, số tuần liên tiếp không hoạt động, số click trung bình mỗi tuần.

## Kết luận EDA

EDA xác định 4 nhóm tín hiệu khả dụng tại cut-off 135: (i) nhân khẩu học (4 biến sau chi-square), (ii) điểm có trọng số trước cut-off (TMA SAFE 71/106), (iii) hành vi VLE theo thời gian (temporal, không dùng `sum_click` tổng), (iv) hành vi nộp bài (submission rate, deadline gap).

## Tài liệu

- [1] John Doe. Dummy reference, 2026. This is a dummy reference to satisfy BibTeX.