

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN CUỐI KỲ
CS313 - KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

HỆ THỐNG CẢNH BÁO SỚM
KẾT QUẢ HỌC TẬP SINH VIÊN
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:

TS. Võ Nguyễn Lê Duy

Nhóm 11:

Họ tên	MSSV
Nguyễn Đặng Ân Phước	24521408
Phạm Quang Hữu Phước	24521411
Văn Đức Tân	24521586
Liên Phúc Thịnh	24521686
Lê Như Thực	24521747

Thành phố Hồ Chí Minh, Tháng 5/2026

Mục lục

1 Khám phá dữ liệu (Exploratory Data Analysis)	1
1.1 Tổng quan dataset và phân phối biến mục tiêu	1
1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu	1
1.3 Phân tích tín hiệu feature	3
1.4 Kết luận EDA	3

1 Khám phá dữ liệu (Exploratory Data Analysis)

1.1 Tổng quan dataset và phân phối biến mục tiêu

OULAD là bộ dữ liệu học tập liên kết gồm 7 bảng quan hệ, bao gồm thông tin của 32.593 lượt đăng ký môn học và hơn 10,6 triệu lượt tương tác trên môi trường học tập ảo (VLE). Biến mục tiêu thể hiện kết quả học tập của người học được chia thành 4 loại `final_result` $\in \{\text{Pass, Withdrawn, Fail, Distinction}\}$.

File	Dòng	Cột có null (%)
studentInfo	32.593	imd_band 3,4%
studentRegistration	32.593	date_unreg 69,1%
studentAssessment	173.912	score 0,1%
studentVle	10.655.280	—
assessments	206	date 5,3%
courses	22	—
vle	6.364	week_from/to 82,4%

Nhãn	Số lượng	Tỉ lệ
Pass	12.361	37,93%
Withdrawn	10.156	31,16%
Fail	7.052	21,64%
Distinction	3.024	9,28%

Trong phạm vi đề án này, nhóm thực hiện chuyển đổi bài toán về dạng **phân loại nhị phân** bằng cách gộp các nhãn mục tiêu ban đầu thành hai nhóm chính:

- **Safe:** Gồm các người học đạt kết quả *Pass* hoặc *Distinction* (nhóm người học an toàn).
- **Not Safe:** Gồm các người học rơi vào trạng thái *Fail* hoặc *Withdrawn* (nhóm người học gặp rủi ro học tập).

Sau khi chuyển đổi, tỷ lệ giữa nhóm Safe ($\sim 47,2\%$) và Not Safe ($\sim 52,8\%$) tương đối cân bằng. Tuy nhiên, nhóm vẫn chọn **Macro-F1** làm độ đo đánh giá chính nhằm đảm bảo mô hình có khả năng phân loại tốt và công bằng trên cả hai nhóm. Điều này giúp tránh tình trạng mô hình dự đoán thiên lệch, từ đó đảm bảo hệ thống cảnh báo sớm đưa ra các quyết định can thiệp đáng tin cậy.

1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu

1.2.1 Phân tích toán tử khuyết mang ngữ nghĩa (Semantic Null)

Một sai lầm phổ biến trong giai đoạn tiền xử lý dữ liệu là việc thực hiện điền giá trị khuyết (`fillna`) hoặc loại bỏ (`dropna`) tất cả các giá trị null một cách máy móc.

Đối với bộ dữ liệu OULAD, các giá trị rỗng không đơn thuần biểu thị sự thiếu hụt dữ liệu (Missing Data), mà ngược lại, mỗi vị trí null đều mang một ngữ nghĩa cụ thể:

Cột	Null %	Ý nghĩa thực	Quyết định
date_unregistration	69,1%	Học đến hết module	Drop (leakage 99,1% Withdrawn)
score	0,1%	Bài không nộp	fillna(0)
imd_band	3,4%	Địa chỉ ngoài UK	Encode "Unknown"
week_from / week_to	82,4%	Resource trải toàn module	Drop cả 2 cột

Cụ thể, thuộc tính date_unregistration có giá trị xuất hiện ở **99,1%** nhóm người học có kết quả *Withdrawn*. Điều này biến đặc trưng này thành một biến đại diện (*proxy*) gần như tuyệt đối cho nhãn mục tiêu, khiến mô hình đối mặt với nguy cơ rò rỉ dữ liệu (*data leakage*) nghiêm trọng. Do đó, việc loại bỏ (*drop*) đặc trưng này là bắt buộc để đảm bảo tính khách quan cho mô hình dự báo.

1.2.2 Chọn cut-off theo data

Median module length 262 ngày. Phân tích phân phối ngày rút môn trên $n = 10.156$ Withdrawn: day 135 (51,6% module) capture $\geq 80\%$ Withdrawn và còn $\sim 48\%$ thời gian can thiệp; day 175 capture $\geq 90\%$ nhưng chỉ còn 33,1% thời gian $\Rightarrow$ quá trễ. Vì pipeline đánh giá trên nhiều mốc cảnh báo, chọn: **cut-off giữa kỳ = 135** (mốc chính, tối ưu coverage vs khả năng can thiệp); **cut-off cuối kỳ = {30, 60, 90, 135}** để theo dõi cách tín hiệu tích lũy theo thời gian khi đánh giá lại ở cuối module.

1.2.3 Kiểm toán leakage tại cut-off 135

Toàn bộ 206 bài đánh giá phân loại SAFE (deadline ≤ 135) vs LEAKAGE (deadline > 135):

Loại	SAFE	LEAK	Median submit ratio	Quyết định
TMA	71	35	0,353	Dùng (đa số SAFE)
CMA	17	59	0,577	Chuẩn hóa theo từng module
Exam	0	6	0,927	Drop hoàn toàn

Median submit ratio Exam (0,927) $\Rightarrow$ bài thi luôn ở cuối kỳ, không có bài SAFE nào tại day 135, drop. CMA có 17/76 SAFE phân bố không đều giữa modules (AAA, EEE không có CMA) $\Rightarrow$ FE chuẩn hoá thành cma_submission_rate.

1.3 Phân tích tín hiệu feature

1.3.1 Tín hiệu nhân khẩu học

Chi-square test ($n = 32.593$) trên các biến categorical so với nhãn `final_result`:

Feature	χ^2	Signal
<code>code_module</code>	1443,2	Rất mạnh
<code>highest_education</code>	1024,7	Rất mạnh
<code>imd_band</code>	666,9	Rất mạnh
<code>region</code>	449,7	Mạnh
<code>age_band</code>	222,7	Mạnh
<code>disability</code>	138,5	Trung bình
<code>gender</code>	16,5	Rất yếu $\rightarrow$ drop

`gender` có χ^2 thấp hơn `code_module` gần **90 lần** $\Rightarrow$ drop. 4 biến mạnh được giữ và encode ordinal để bảo toàn quan hệ monotonic cho tree-based model.

1.3.2 Hiệu ứng kỳ học (Semester B vs J)

Pass rate kỳ B (tháng 2) = 43,67% ($n = 12.488$), kỳ J (tháng 10) = 49,40% ($n = 20.105$). Chênh lệch không đồng đều theo module: CCC diff = $-6,38$ pp, EEE diff = $-6,28$ pp (vượt ngưỡng ± 5 pp) $\Rightarrow$ semester **phải là feature**, không lọc bỏ.

1.4 Kết luận EDA

EDA xác định các nhóm tín hiệu khả dụng tại cut-off 135: (i) nhân khẩu học (4 biến sau chi-square), (ii) điểm có trọng số trước cut-off (TMA SAFE 71/106), (iii) hành vi nộp bài (submission rate, deadline gap). Tín hiệu hành vi VLE sẽ phân tích chi tiết ở giai đoạn Feature Engineering sau khi thống nhất pipeline nhị phân (At-Risk vs Not At-Risk).

Tài liệu

- [1] John Doe. Dummy reference, 2026. This is a dummy reference to satisfy BibTeX.