

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN CUỐI KỲ
CS313 - KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

HỆ THỐNG CẢNH BÁO SỚM
KẾT QUẢ HỌC TẬP SINH VIÊN
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:

TS. Võ Nguyễn Lê Duy

Nhóm 11:

Họ tên	MSSV
Nguyễn Đặng Ân Phước	24521408
Phạm Quang Hữu Phước	24521411
Văn Đức Tân	24521586
Liên Phúc Thịnh	24521686
Lê Như Thực	24521747

Thành phố Hồ Chí Minh, Tháng 5/2026

Mục lục

1 Khám phá dữ liệu (Exploratory Data Analysis)	1
1.1 Tổng quan dataset và phân phối biến mục tiêu	1
1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu	1
1.3 Phân tích tín hiệu feature	3
1.4 Kết luận EDA	3
2 Kỹ thuật đặc trưng (Feature Engineering)	4
2.1 Thiết lập chung và Tiền xử lý dữ liệu	4
2.2 Nhóm đặc trưng tĩnh (Static Features)	4
2.3 Nhóm đặc trưng động hàng tuần (Weekly Causal Dynamic Features)	4
2.4 Features Encoding và Out-of-Time (OOT) Split	5
2.5 Chuẩn hóa dữ liệu với Causal Scaling	6
2.6 Phân tích tương quan và Lọc bỏ đặc trưng (Feature Selection)	6
3 Mô hình hóa (Modeling)	7
3.1 Phạm vi thử nghiệm	7
3.2 Mô hình XGBoost và LightGBM	7
3.3 Mô hình LSTM và Transformer	8
3.4 Kết luận	8

1 Khám phá dữ liệu (Exploratory Data Analysis)

1.1 Tổng quan dataset và phân phối biến mục tiêu

OULAD là bộ dữ liệu học tập liên kết gồm 7 bảng quan hệ, bao gồm thông tin của 32.593 lượt đăng ký môn học và hơn 10,6 triệu lượt tương tác trên môi trường học tập ảo (VLE). Biến mục tiêu thể hiện kết quả học tập của người học được chia thành 4 loại `final_result` $\in \{\text{Pass, Withdrawn, Fail, Distinction}\}$.

File	Dòng	Cột có null (%)
studentInfo	32.593	imd_band 3,4%
studentRegistration	32.593	date_unreg 69,1%
studentAssessment	173.912	score 0,1%
studentVle	10.655.280	—
assessments	206	date 5,3%
courses	22	—
vle	6.364	week_from/to 82,4%

Nhãn	Số lượng	Tỉ lệ
Pass	12.361	37,93%
Withdrawn	10.156	31,16%
Fail	7.052	21,64%
Distinction	3.024	9,28%

Trong phạm vi đề án này, nhóm thực hiện chuyển đổi bài toán về dạng **phân loại nhị phân** bằng cách gộp các nhãn mục tiêu ban đầu thành hai nhóm chính:

- **NOT AT-RISK**: Gồm các người học đạt kết quả *Pass* hoặc *Distinction* (nhóm người học an toàn).
- **AT-RISK**: Gồm các người học rơi vào trạng thái *Fail* hoặc *Withdrawn* (nhóm người học gặp rủi ro học tập).

Sau khi chuyển đổi, tỷ lệ giữa nhóm NOT AT-RISK ($\sim 47,2\%$) và AT-RISK ($\sim 52,8\%$) tương đối cân bằng. Tuy nhiên, nhóm vẫn chọn **Macro-F1** làm độ đo đánh giá chính nhằm đảm bảo mô hình có khả năng phân loại tốt và công bằng trên cả hai nhóm. Điều này giúp tránh tình trạng mô hình dự đoán thiên lệch, từ đó đảm bảo hệ thống cảnh báo sớm đưa ra các quyết định can thiệp đáng tin cậy.

1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu

1.2.1 Phân tích toán tử khuyết mang ngữ nghĩa (Semantic Null)

Một sai lầm phổ biến trong giai đoạn tiền xử lý dữ liệu là việc thực hiện điền giá trị khuyết (`fillna`) hoặc loại bỏ (`dropna`) tất cả các giá trị null một cách máy móc.

Đối với bộ dữ liệu OULAD, các giá trị rỗng không đơn thuần biểu thị sự thiếu hụt dữ liệu (Missing Data), mà ngược lại, mỗi vị trí null đều mang một ngữ nghĩa cụ thể:

Cột	Null %	Ý nghĩa thực	Quyết định
date_unregistration	69,1%	Học đến hết module	Drop (leakage 99,1% Withdrawn)
score	0,1%	Bài không nộp	fillna(0)
imd_band	3,4%	Địa chỉ ngoài UK	Encode "Unknown"
week_from / week_to	82,4%	Resource trải toàn module	Drop cả 2 cột

Cụ thể, thuộc tính date_unregistration có tỷ lệ null **69,1%** trong toàn bộ bộ dữ liệu. Tuy nhiên, trong số những người học có kết quả *Withdrawn*, **99,1%** trường hợp này có giá trị không rỗng (tức là có ngày rút khỏi môn). Điều này cho thấy rằng sự xuất hiện của thuộc tính này gần như hoàn toàn liên kết với nhãn *Withdrawn*, biến nó thành một biến đại diện (*proxy*) tuyệt đối cho kết quả đã rút khỏi môn. Khi một mô hình học được mối liên hệ này, nó sẽ dựa vào sự có mặt hay vắng mặt của giá trị này để dự đoán, thay vì học từ các đặc trưng thực sự liên quan. Đây là rò rỉ dữ liệu (*data leakage*) vì thông tin này thường chỉ khả dụng sau khi người học đã đưa ra quyết định rút khỏi môn. Do đó, loại bỏ (*drop*) đặc trưng này là bắt buộc để đảm bảo mô hình học được các mối liên hệ có ý nghĩa thực tế.

1.2.2 Chọn cut-off theo data

Median module length 262 ngày. Phân tích phân phối ngày rút môn trên $n = 10.156$ Withdrawn: day 135 capture 80,4% Withdrawn; day 170 capture 89,3% và còn 92 ngày (35,1% thời gian module) để can thiệp. Nhóm chọn **cut-off = 170** làm mốc cắt dữ liệu cho Feature Engineering, tương ứng **25 tuần** học ($T_{\max} = \lceil 170/7 \rceil$).

Hai hướng tiếp cận mô hình sử dụng chung dữ liệu FE này:

- **Mô hình cây (XGBoost, LightGBM):** Dự đoán tại các mốc tuần {4, 8, 12, 16, 20, 24}. Tại mỗi mốc tuần t , mô hình chỉ nhìn dữ liệu từ ngày 0 đến ngày $7t - 1$, đảm bảo không rò rỉ thông tin từ tương lai.
- **Mô hình chuỗi (LSTM, Transformer):** Nhận toàn bộ chuỗi 25 tuần dưới dạng panel. Tại mỗi tuần t , mô hình chỉ quan sát dữ liệu đến tuần t nhờ cơ chế che nhân quả (*causal masking*), cho phép dự đoán liên tục mà không cần mốc cắt cố định.

1.2.3 Kiểm toán rò rỉ dữ liệu

Toàn bộ 206 bài đánh giá phân loại NOT AT-RISK ($\text{deadline} \leq 170$) vs AT-RISK ($\text{deadline} > 170$):

Loại	NOT AT-RISK	AT-RISK	Median submit ratio	Quyết định
TMA	89	17	0,349	Dùng (đa số NOT AT-RISK)
CMA	24	52	0,561	Chuẩn hóa theo từng module
Exam	0	13	0,927	Drop hoàn toàn

Median submit ratio Exam (0,927) $\Rightarrow$ bài thi luôn ở cuối kỳ, không có bài NOT AT-RISK nào tại day 170, drop. CMA có 24/76 NOT AT-RISK phân bố không đều giữa modules (FFF, GGG không có CMA NOT AT-RISK trước day 170) $\Rightarrow$ FE chuẩn hoá thành `cma_submission_rate`.

1.3 Phân tích tín hiệu feature

1.3.1 Tín hiệu nhân khẩu học

Chi-square test ($n = 32.593$) trên các biến categorical so với nhãn `final_result`:

Feature	χ^2	Signal
<code>code_module</code>	1443,2	Rất mạnh
<code>highest_education</code>	1024,7	Rất mạnh
<code>imd_band</code>	666,9	Rất mạnh
<code>region</code>	449,7	Mạnh
<code>age_band</code>	222,7	Mạnh
<code>gender</code>	16,5	Rất yếu $\rightarrow$ drop

`gender` có χ^2 thấp hơn `code_module` gần **90 lần** $\Rightarrow$ drop. 4 biến mạnh được giữ và encode ordinal để bảo toàn quan hệ monotonic cho tree-based model.

Đặc trưng `disability` (dù có $\chi^2 = 138,5$) được loại bỏ vì lý do đạo đức. Sử dụng tình trạng khuyết tật như một yếu tố dự báo kết quả học tập có thể dẫn đến phân biệt đối xử và không công bằng với nhóm học sinh có khuyết tật. Do đó, mô hình chỉ sử dụng 4 biến nhân khẩu học còn lại.

1.3.2 Hiệu ứng kỳ học (Semester B vs J)

Pass rate kỳ B (tháng 2) = 43,67% ($n = 12.488$), kỳ J (tháng 10) = 49,40% ($n = 20.105$). Chênh lệch không đồng đều theo module: CCC diff = $-6,38$ pp, EEE diff = $-6,28$ pp (vượt ngưỡng ± 5 pp) $\Rightarrow$ semester **phải là feature**, không lọc bỏ.

1.4 Kết luận EDA

EDA xác định các nhóm tín hiệu khả dụng tại cut-off 170: (i) nhân khẩu học (4 biến sau chi-square), (ii) điểm có trọng số trước cut-off (TMA NOT AT-RISK 89/106),

(iii) hành vi nộp bài (submission rate, deadline gap). Tín hiệu hành vi VLE sẽ phân tích chi tiết ở giai đoạn Feature Engineering sau khi thống nhất pipeline nhị phân (AT-RISK vs NOT AT-RISK).

2 Kỹ thuật đặc trưng (Feature Engineering)

2.1 Thiết lập chung và Tiền xử lý dữ liệu

Dữ liệu được tái cấu trúc thành dạng chuỗi tuần (*weekly panel*) cho mô hình LSTM và Transformer với các thiết lập:

- **Mốc cắt (*Cut-off Day*):** Ngày **170** của học kỳ, tương ứng tối đa **25 tuần** học ($T_{MAX} = 25$, độ dài tuần 7 ngày). Các tương tác và điểm số sau ngày 170 bị loại bỏ.
- **Nhãn mục tiêu:**
 - At Risk (Fail/Withdrawn): Gán 1.
 - Not At Risk (Pass/Distinction): Gán 0.

Quy trình làm sạch dữ liệu thô bao gồm:

- `date_registration`: Trung vị theo đợt học (*module-presentation*).
- `imd_band`, `age_band`: “Unknown”.
- `score` (khuyết): 0.
- `date_unregistration`, `week_from`, `week_to`: Loại bỏ hoàn toàn.

2.2 Nhóm đặc trưng tĩnh (Static Features)

Đặc trưng tĩnh là thông tin cố định, được truyền vào mô hình tại mọi bước thời gian:

- **Nhân khẩu học:** `gender`, `age_band`, `imd_band`, `region`, `highest_education`, `disability`, `studied_credits` và `num_of_prev_attempts`.
- **Bối cảnh học tập:** `date_registration`, `code_module`, `code_presentation`, `module_semester` và `semester`.
- **Tương tác trước khóa học** ($date < 0$): `pre_course_clicks`, `pre_course_active_days` và `has_pre_course_activity`.

2.3 Nhóm đặc trưng động hàng tuần (Weekly Causal Dynamic Features)

Đặc trưng tại tuần t chỉ được tổng hợp từ dữ liệu phát sinh từ ngày 0 đến $7t - 1$ để đảm bảo tính nhân quả. Quy trình trích xuất gồm hai nhóm:

1. Đặc trưng động theo tuần (Weekly Features):

- **Tương tác VLE trong tuần học t :** `clicks_this_week` (tổng click), `active_days_this_week` (ngày hoạt động), thống kê click ngày (`max_daily_clicks_week`, `median_daily_clicks_week`, `std_clicks_week`),

click ngày cuối tuần (`weekend_clicks_week`) và lượng tương tác theo 4 tài nguyên chính (`oucontent`, `forumng`, `homepage`, `quiz`).

- **Kết quả đánh giá trong tuần học t :** Số bài đánh giá đã nộp, tổng điểm nhận được, tổng trọng số, tổng điểm có trọng số tương ứng và số ngày nộp trước hạn trung bình trong tuần. Đồng thời so sánh số bài TMA và CMA thực tế đã nộp với số bài đến hạn (**due deadline**) trong tuần t .

2. Đặc trưng động nhân quả (Causal Dynamic Features):

- **Tương tác VLE:**
 - `cum_clicks`: Tổng click.
 - `cum_active_days`: Số ngày tương tác.
 - `active_rate_so_far`: Tỷ lệ ngày hoạt động.
 - `clicks_per_active_day_cum`: Click trung bình mỗi ngày hoạt động.
 - `days_since_last_active`: Số ngày từ lần tương tác cuối.
 - `active_span_so_far`: Khoảng thời gian hoạt động.
- **Xu hướng tương tác và khoảng trống:**
 - `click_slope_recent`, `click_slope_r2_recent`: Hệ số góc và hệ số xác định trên 4 tuần gần nhất $[t-3, t]$.
 - `activity_density_so_far`: Mật độ ngày hoạt động.
 - `gap_std_so_far`, `gap_trend_so_far`: Độ lệch chuẩn và xu hướng khoảng cách giữa các ngày hoạt động liên tiếp.
 - `ratio_{type}_so_far`: Tỷ lệ click theo tài nguyên.
 - `weekend_ratio_so_far`: Tỷ lệ click cuối tuần.
- **Kết quả học tập:**
 - `mean_score_so_far`: Điểm trung bình.
 - `weighted_score_so_far`: Điểm trọng số.
 - `tma_submission_rate_so_far`, `cma_submission_rate_so_far`: Tỷ lệ nộp bài TMA và CMA.
 - `n_missing_so_far`: Số bài đánh giá bỏ lỡ.

2.4 Features Encoding và Out-of-Time (OOT) Split

Phương pháp mã hóa các đặc trưng gồm:

- **Ordinal Encoding:** Áp dụng cho các biến thứ bậc gồm `highest_education_encoded`, `age_band_encoded` và `imd_band_encoded`.
- **Binary Encoding:** Dành cho `semester_enc`, `gender_encoded`, `disability_encoded` và đợt học `module_semester_encoded`.
- **One-hot Encoding:** Chuyển đổi vùng địa lý `region` thành 12 biến giả nhị phân. Tập dữ liệu thô ban đầu gồm 33 đặc trưng động và 25 đặc trưng tĩnh.

Chiến lược phân chia Out-of-Time (OOT) theo kỳ học thực tế:

- **Tập Train (21.333 lượt học):** Gồm dữ liệu sinh viên thuộc các kỳ học cũ (2013B, 2013J, 2014B).
- **Tập Test (11.260 lượt học):** Gồm dữ liệu sinh viên thuộc kỳ học cuối cùng (2014J).

Dữ liệu sau khi phân chia được kết xuất thành ba định dạng phục vụ huấn luyện:

- **LONG Format** (`df_train_long.csv`, `df_test_long.csv`): Dạng bảng tuần (*panel data*, 25 dòng/lượt học) cho LSTM và Transformer.
- **WIDE Format** (`df_train.csv`, `df_test.csv`): Dạng phẳng (snapshot tại tuần học cuối $T = 24$) cho XGBoost và LightGBM.
- **TENSOR Format** (các file `.npy`): Các mảng numpy 3D/2D đã chuẩn hóa để nạp trực tiếp vào PyTorch.

2.5 Chuẩn hóa dữ liệu với Causal Scaling

Chuẩn hóa dữ liệu bằng `StandardScaler` tránh rò rỉ thông tin từ tập Test vào tập Train.

2.6 Phân tích tương quan và Lọc bỏ đặc trưng (Feature Selection)

Quy trình lọc bỏ đặc trưng:

- **Kiểm định tương quan Pearson:** Tính toán tương quan giữa từng đặc trưng số động với nhãn mục tiêu tại tuần cuối cùng ($T = 24$), giữ lại các đặc trưng có $|corr| \geq 0,05$.
- **Kiểm định Chi-square (χ^2):** Loại bỏ các đặc trưng có mức ý nghĩa p -value $> 0,05$.

Kết quả của quá trình lọc chọn đặc trưng:

- **Dynamic Features:** Loại bỏ **5 đặc trưng**: `ratio_subpage_so_far`, `n_submitted_week`, `ratio_url_so_far`, `gap_std_so_far`, `weekend_clicks_week`.
- **Static Features:** Loại bỏ **3 đặc trưng**: 3 biến giả khu vực địa lý (`region_Scotland` ($p = 0.76$), `region_East_Midlands_Region` ($p = 0.16$), `region_Wales` ($p = 0.06$))

Mô hình LSTM và Transformer cuối cùng sẽ chỉ tiếp nhận chuỗi Tensor `X_seq` gồm 34 đặc trưng động và Tensor tĩnh `X_static` gồm 16 đặc trưng tĩnh đã được tinh lọc.

3 Mô hình hóa (Modeling)

3.1 Phạm vi thử nghiệm

Phần modeling trong đề án được thực hiện trên hai nhánh khác nhau: nhánh mô hình học máy truyền thống và nhánh mô hình chuỗi. Các mô hình được đánh giá theo nhiều mốc thời gian để phản ánh đúng bài toán cảnh báo sớm. Với nhánh ML, nhóm sử dụng các snapshot tuần 4, 8, 12, 16, 20 và 24. Với nhánh sequence, mô hình được đánh giá liên tục theo từng tuần, từ giai đoạn đầu khóa học đến cuối khóa học. Các metric chính gồm AUC-ROC, Accuracy, Precision, Recall và F1-score.

3.2 Mô hình XGBoost và LightGBM

Trong nhánh ML truyền thống, nhóm huấn luyện hai mô hình tree boosting là **XGBoost** và **LightGBM** cho từng snapshot tuần. Mỗi snapshot chỉ sử dụng thông tin đã có tới thời điểm tương ứng, nhờ đó mô phỏng được tình huống hệ thống cảnh báo được cập nhật định kỳ trong quá trình học.

Kết quả LightGBM

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8221	0,7397	0,7428	0,7570	0,7499
8	0,8738	0,7811	0,8583	0,6890	0,7644
12	0,8870	0,7981	0,8135	0,7892	0,8012
16	0,9263	0,8518	0,9169	0,7834	0,8449
20	0,9441	0,8774	0,9200	0,8347	0,8753
24	0,9626	0,9015	0,9372	0,8670	0,9007

Kết quả XGBoost

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8266	0,7263	0,6948	0,8363	0,7590
8	0,8775	0,7829	0,8592	0,6921	0,7666
12	0,8826	0,7893	0,7934	0,7994	0,7964
16	0,9295	0,8485	0,9211	0,7722	0,8401
20	0,9454	0,8778	0,9259	0,8292	0,8749
24	0,9624	0,9012	0,9391	0,8642	0,9001

Kết quả cho thấy cả hai mô hình đều cải thiện rõ khi có thêm dữ liệu theo thời gian. Ở tuần 4, mô hình đã đạt F1 khoảng 0,75, cho thấy các tín hiệu ban đầu đủ mạnh để phát cảnh báo sớm. Đến tuần 24, F1 đạt khoảng 0,90 và AUC vượt 0,96.

3.3 Mô hình LSTM và Transformer

Nhánh sequence sử dụng dữ liệu dạng chuỗi theo tuần để huấn luyện mô hình **LSTM** và **Transformer**. Mô hình nhận hai nhóm đầu vào: đặc trưng động theo thời gian và đặc trưng tĩnh của sinh viên.

Kết quả LSTM

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8147	0,7352	0,8106	0,6343	0,7117
8	0,8790	0,7884	0,8864	0,6760	0,7670
12	0,8969	0,8171	0,8866	0,7398	0,8066
16	0,9311	0,8571	0,9338	0,7779	0,8487
20	0,9472	0,8800	0,9616	0,7991	0,8728
24	0,9639	0,9023	0,9659	0,8401	0,8986
33	0,9808	0,9329	0,9752	0,8926	0,9321

Kết quả Transformer

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8277	0,7481	0,7805	0,7114	0,7443
8	0,8791	0,7923	0,8663	0,7058	0,7779
12	0,8963	0,8099	0,8490	0,7675	0,8062
16	0,9288	0,8552	0,8867	0,8244	0,8544
20	0,9430	0,8763	0,9214	0,8308	0,8738
24	0,9629	0,8996	0,9202	0,8818	0,9006
33	0,9775	0,9295	0,9742	0,8866	0,9284

LSTM và Transformer thể hiện xu hướng tăng ổn định theo số tuần quan sát. Ở tuần 12, F1 đạt 0,8; đến tuần 24 đạt 0,9; và ở tuần 33 đạt 0,93. Điều này cho thấy mô hình khai thác tốt thông tin tích lũy dài hạn trong chuỗi hành vi học tập.

3.4 Kết luận

Ở các tuần 20–24, cả mô hình ML theo snapshot và mô hình sequence đều đạt F1 xấp xỉ 0,87–0,90, cho thấy hệ thống đã có thể đưa ra cảnh báo tương đối tin cậy trước khi kết thúc khóa học. Các mô hình đã sẵn sàng để được đóng gói và triển khai trên ứng dụng thực tế.