

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN CUỐI KỲ
CS313 - KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

HỆ THỐNG CẢNH BÁO SỚM
KẾT QUẢ HỌC TẬP SINH VIÊN
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:
Võ Nguyễn Lê Duy

Nhóm 11:

Họ tên	MSSV
Nguyễn Đặng Ân Phước	24521408
Phạm Quang Hữu Phước	24521411
Văn Đức Tân	24521586
Liên Phúc Thịnh	24521686
Lê Như Thực	24521747

Thành phố Hồ Chí Minh, Tháng 5/2026

Mục lục

1 Khám phá dữ liệu (Exploratory Data Analysis)	2
1.1 Tổng quan dataset và phân phối biến mục tiêu	2
1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu	2
1.3 Phân tích tín hiệu feature	3

1 Khám phá dữ liệu (Exploratory Data Analysis)

1.1 Tổng quan dataset và phân phối biến mục tiêu

OULAD gồm 7 bảng quan hệ, phủ 32.593 lượt đăng ký học phần với 10.655.280 lượt tương tác VLE. Bài toán phân loại 4 nhãn `final_result` $\in \{\text{Pass, Withdrawn, Fail, Distinction}\}$.

File	Dòng	Cột có null (%)
<code>studentInfo</code>	32.593	<code>imd_band</code> 3,4%
<code>studentRegistration</code>	32.593	<code>date_unreg</code> 69,1%
<code>studentAssessment</code>	173.912	<code>score</code> 0,1%
<code>studentVle</code>	10.655.280	—
<code>assessments</code>	206	<code>date</code> 5,3%
<code>courses</code>	22	—
<code>vle</code>	6.364	<code>week_from/to</code> 82,4%

Nhãn	Số lượng	Tỉ lệ
Pass	12.361	37,93%
Withdrawn	10.156	31,16%
Fail	7.052	21,64%
Distinction	3.024	9,28%

Distinction chiếm 9,28% — class nhỏ nhất, ít hơn Pass ~ 4 lần $\Rightarrow$ chọn **Macro-F1** làm metric chính để không bỏ qua class thiểu số.

1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu

2.1 Semantic Null — null không phải thiếu data

Sai lầm phổ biến là `fillna/drop` tất cả null cơ học. Trong OULAD mỗi null đều mang ngữ nghĩa cụ thể:

Cột	Null %	Ý nghĩa thực	Quyết định
<code>date_unregistration</code>	69,1%	NULL = học đến hết module	Giữ; drop khỏi features (leakage)
<code>score</code>	0,1%	Bài không nộp	<code>fillna(0)</code>
<code>imd_band</code>	3,4%	Địa chỉ ngoài UK	Encode "Unknown"
<code>week_from / week_to</code>	82,4%	Resource trải toàn module	Drop cả 2 cột

`date_unregistration` có giá trị ở **99,1%** ca Withdrawn $\Rightarrow$ proxy gần tuyệt đối của label, bắt buộc drop để tránh leakage 100%. Ngược lại, NULL ở 69,1% còn lại là tín hiệu *positive* (sinh viên tiếp tục học).

2.2 Chọn cut-off theo data

Median module length 262 ngày. Phân tích phân phối ngày rút môn trên $n = 10.156$ Withdrawn: day 135 (51,6% module) capture $\geq 80\%$ Withdrawn và còn $\sim 48\%$ thời gian can thiệp; day 175 capture $\geq 90\%$ nhưng chỉ còn 33,1% thời gian $\Rightarrow$ quá trễ. Chọn **CUTOFF_DAY = 135** — cân bằng tối ưu giữa coverage và khả năng can thiệp.

2.3 Kiểm toán leakage tại cut-off 135

Toàn bộ 206 bài đánh giá phân loại SAFE (`deadline  $\leq 135$`) vs LEAK-AGE (`deadline  $> 135$`):

Loại	SAFE	LEAK	Median submit ratio	Quyết định
TMA	71	35	0,353	✓ Dừng (đa số SAFE)
CMA	17	59	0,577	✓ Chuẩn hóa theo từng module
Exam	0	6	0,927	× Drop hoàn toàn

Median submit ratio Exam (0,927) $\Rightarrow$ bài thi luôn ở cuối kỳ, không có bài SAFE nào tại day 135, drop. CMA có 17/76 SAFE phân bố không đều giữa modules (AAA, EEE không có CMA) $\Rightarrow$ FE chuẩn hoá thành `cma_submission_rate`.

1.3 Phân tích tín hiệu feature

3.1 Tín hiệu nhân khẩu học

Chi-square test ($n = 32.593$) trên các biến categorical so với nhãn `final_result`:

Feature	χ^2	Signal
<code>code_module</code>	1443,2	Rất mạnh
<code>highest_education</code>	1024,7	Rất mạnh
<code>imd_band</code>	666,9	Rất mạnh
<code>region</code>	449,7	Mạnh
<code>age_band</code>	222,7	Mạnh
<code>disability</code>	138,5	Trung bình
<code>gender</code>	16,5	Rất yếu $\rightarrow$ drop

`gender` có χ^2 thấp hơn `code_module` gần **90 lần** $\Rightarrow$ drop. 4 biến mạnh được giữ và encode ordinal để bảo toàn quan hệ monotonic cho tree-based model.

3.2 Hiệu ứng kỳ học (Semester B vs J)

Pass rate kỳ B (tháng 2) = 43,67% ($n = 12.488$), kỳ J (tháng 10) = 49,40% ($n = 20.105$). Chênh lệch không đồng đều theo module: CCC diff = $-6,38$ pp, EEE diff = $-6,28$ pp (vượt ngưỡng ± 5 pp) $\Rightarrow$ semester **phải là feature**, không lọc bỏ.

3.3 Tín hiệu hành vi VLE

Phân tích 10.655.280 dòng `studentVle.csv` (log click của sinh viên trên hệ thống học trực tuyến) trong khoảng ngày $[-\infty, 135]$ phát hiện 3 pattern chính:

- **Pre-course** (click trước ngày khai giảng, `date` < 0): tương quan Spearman với nhãn rất rõ — $\rho_{\text{pre_clicks}} = +0,2684$, $\rho_{\text{pre_days}} = +0,2471$ ($p \approx 0$). $\Rightarrow$ sinh viên *xem trước tài liệu* đã là tín hiệu cảnh báo sớm.
- **Activity ratio** (tỉ lệ click Distinction / Withdrawn theo loại tài nguyên): forum $4,65\times$, nội dung học $4,09\times$, quiz $1,44\times$. $\Rightarrow$ Withdrawn gần như *không vào forum*, khác biệt mạnh nhất ở forum và nội dung.
- **Temporal** (phân phối click theo thời gian): Withdrawn có peak sớm (ngày 0–30) rồi biến mất; Pass/Distinction click đều đặn đến cuối. $\Rightarrow$ tổng click (`sum_click`) kém phân biệt; FE cần các feature thời gian: số ngày active, ngày active cuối, số tuần liên tiếp không hoạt động, số click trung bình mỗi tuần.

Kết luận EDA

EDA xác định 4 nhóm tín hiệu khả dụng tại cut-off 135: (i) nhân khẩu học (4 biến sau chi-square), (ii) điểm có trọng số trước cut-off (TMA SAFE 71/106), (iii) hành vi VLE theo thời gian (temporal, không dùng `sum_click` tổng), (iv) hành vi nộp bài (submission rate, deadline gap). Chương Feature Engineering bám sát 4 nhóm này, loại hoàn toàn leakage và chuẩn hoá theo module.

Tài liệu

- [1] John Doe. Dummy reference, 2026. This is a dummy reference to satisfy BibTeX.