

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN CUỐI KỲ
CS313 - KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

HỆ THỐNG CẢNH BÁO SỚM
KẾT QUẢ HỌC TẬP SINH VIÊN
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:

TS. Võ Nguyễn Lê Duy

Nhóm 11:

Họ tên	MSSV
Nguyễn Đặng Ân Phước	24521408
Phạm Quang Hữu Phước	24521411
Văn Đức Tân	24521586
Liên Phúc Thịnh	24521686
Lê Như Thực	24521747

Thành phố Hồ Chí Minh, Tháng 5/2026

Mục lục

1 Khám phá dữ liệu (Exploratory Data Analysis)	1
1.1 Tổng quan dataset và phân phối biến mục tiêu	1
1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu	1
1.3 Phân tích tín hiệu feature	3
1.4 Kết luận EDA	3
2 Kỹ thuật đặc trưng (Feature Engineering)	4
2.1 Thiết lập chung	4
2.2 Tiền xử lý dữ liệu và làm sạch	4
2.3 Nhóm đặc trưng tương tác trước khóa học	4
2.4 Nhóm đặc trưng tương tác hệ thống (VLE)	4
2.5 Nhóm đặc trưng đánh giá học tập	5
2.6 Nhóm đặc trưng nhân khẩu học	5
2.7 Chiến lược phân chia dữ liệu và chuẩn hóa	6

1 Khám phá dữ liệu (Exploratory Data Analysis)

1.1 Tổng quan dataset và phân phối biến mục tiêu

OULAD là bộ dữ liệu học tập liên kết gồm 7 bảng quan hệ, bao gồm thông tin của 32.593 lượt đăng ký môn học và hơn 10,6 triệu lượt tương tác trên môi trường học tập ảo (VLE). Biến mục tiêu thể hiện kết quả học tập của người học được chia thành 4 loại `final_result` $\in \{\text{Pass, Withdrawn, Fail, Distinction}\}$.

File	Dòng	Cột có null (%)
studentInfo	32.593	imd_band 3,4%
studentRegistration	32.593	date_unreg 69,1%
studentAssessment	173.912	score 0,1%
studentVle	10.655.280	—
assessments	206	date 5,3%
courses	22	—
vle	6.364	week_from/to 82,4%

Nhãn	Số lượng	Tỉ lệ
Pass	12.361	37,93%
Withdrawn	10.156	31,16%
Fail	7.052	21,64%
Distinction	3.024	9,28%

Trong phạm vi đề án này, nhóm thực hiện chuyển đổi bài toán về dạng **phân loại nhị phân** bằng cách gộp các nhãn mục tiêu ban đầu thành hai nhóm chính:

- **Safe:** Gồm các người học đạt kết quả *Pass* hoặc *Distinction* (nhóm người học an toàn).
- **Not Safe:** Gồm các người học rơi vào trạng thái *Fail* hoặc *Withdrawn* (nhóm người học gặp rủi ro học tập).

Sau khi chuyển đổi, tỷ lệ giữa nhóm Safe ($\sim 47,2\%$) và Not Safe ($\sim 52,8\%$) tương đối cân bằng. Tuy nhiên, nhóm vẫn chọn **Macro-F1** làm độ đo đánh giá chính nhằm đảm bảo mô hình có khả năng phân loại tốt và công bằng trên cả hai nhóm. Điều này giúp tránh tình trạng mô hình dự đoán thiên lệch, từ đó đảm bảo hệ thống cảnh báo sớm đưa ra các quyết định can thiệp đáng tin cậy.

1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu

1.2.1 Phân tích toán tử khuyết mang ngữ nghĩa (Semantic Null)

Một sai lầm phổ biến trong giai đoạn tiền xử lý dữ liệu là việc thực hiện điền giá trị khuyết (`fillna`) hoặc loại bỏ (`dropna`) tất cả các giá trị null một cách máy móc.

Đối với bộ dữ liệu OULAD, các giá trị rỗng không đơn thuần biểu thị sự thiếu hụt dữ liệu (Missing Data), mà ngược lại, mỗi vị trí null đều mang một ngữ nghĩa cụ thể:

Cột	Null %	Ý nghĩa thực	Quyết định
date_unregistration	69,1%	Học đến hết module	Drop (leakage 99,1% Withdrawn)
score	0,1%	Bài không nộp	fillna(0)
imd_band	3,4%	Địa chỉ ngoài UK	Encode "Unknown"
week_from / week_to	82,4%	Resource trải toàn module	Drop cả 2 cột

Cụ thể, thuộc tính date_unregistration có giá trị xuất hiện ở **99,1%** nhóm người học có kết quả *Withdrawn*. Điều này biến đặc trưng này thành một biến đại diện (*proxy*) gần như tuyệt đối cho nhãn mục tiêu, khiến mô hình đối mặt với nguy cơ rò rỉ dữ liệu (*data leakage*) nghiêm trọng. Do đó, việc loại bỏ (*drop*) đặc trưng này là bắt buộc để đảm bảo tính khách quan cho mô hình dự báo.

1.2.2 Chọn cut-off theo data

Median module length 262 ngày. Phân tích phân phối ngày rút môn trên $n = 10.156$ Withdrawn: day 135 (51,6% module) capture $\geq 80\%$ Withdrawn và còn $\sim 48\%$ thời gian can thiệp; day 175 capture $\geq 90\%$ nhưng chỉ còn 33,1% thời gian $\Rightarrow$ quá trễ. Vì pipeline đánh giá trên nhiều mốc cảnh báo, chọn: **cut-off giữa kỳ = 135** (mốc chính, tối ưu coverage vs khả năng can thiệp); **cut-off cuối kỳ = {30, 60, 90, 135}** để theo dõi cách tín hiệu tích lũy theo thời gian khi đánh giá lại ở cuối module.

1.2.3 Kiểm toán leakage tại cut-off 135

Toàn bộ 206 bài đánh giá phân loại SAFE (deadline ≤ 135) vs LEAKAGE (deadline > 135):

Loại	SAFE	LEAK	Median submit ratio	Quyết định
TMA	71	35	0,353	Dùng (đa số SAFE)
CMA	17	59	0,577	Chuẩn hóa theo từng module
Exam	0	6	0,927	Drop hoàn toàn

Median submit ratio Exam (0,927) $\Rightarrow$ bài thi luôn ở cuối kỳ, không có bài SAFE nào tại day 135, drop. CMA có 17/76 SAFE phân bố không đều giữa modules (AAA, EEE không có CMA) $\Rightarrow$ FE chuẩn hoá thành cma_submission_rate.

1.3 Phân tích tín hiệu feature

1.3.1 Tín hiệu nhân khẩu học

Chi-square test ($n = 32.593$) trên các biến categorical so với nhãn `final_result`:

Feature	χ^2	Signal
<code>code_module</code>	1443,2	Rất mạnh
<code>highest_education</code>	1024,7	Rất mạnh
<code>imd_band</code>	666,9	Rất mạnh
<code>region</code>	449,7	Mạnh
<code>age_band</code>	222,7	Mạnh
<code>disability</code>	138,5	Trung bình
<code>gender</code>	16,5	Rất yếu $\rightarrow$ drop

`gender` có χ^2 thấp hơn `code_module` gần **90 lần** $\Rightarrow$ drop. 4 biến mạnh được giữ và encode ordinal để bảo toàn quan hệ monotonic cho tree-based model.

1.3.2 Hiệu ứng kỳ học (Semester B vs J)

Pass rate kỳ B (tháng 2) = 43,67% ($n = 12.488$), kỳ J (tháng 10) = 49,40% ($n = 20.105$). Chênh lệch không đồng đều theo module: CCC diff = $-6,38$ pp, EEE diff = $-6,28$ pp (vượt ngưỡng ± 5 pp) $\Rightarrow$ semester **phải là feature**, không lọc bỏ.

1.4 Kết luận EDA

EDA xác định các nhóm tín hiệu khả dụng tại cut-off 135: (i) nhân khẩu học (4 biến sau chi-square), (ii) điểm có trọng số trước cut-off (TMA SAFE 71/106), (iii) hành vi nộp bài (submission rate, deadline gap). Tín hiệu hành vi VLE sẽ phân tích chi tiết ở giai đoạn Feature Engineering sau khi thống nhất pipeline nhị phân (At-Risk vs Not At-Risk).

2 Kỹ thuật đặc trưng (Feature Engineering)

2.1 Thiết lập chung

Trong quá trình trích xuất đặc trưng, nhóm thiết lập mốc thời gian cắt dữ liệu (*Cut-off Day*) tại ngày **135**. Giá trị `RANDOM_SEED = 42` được sử dụng xuyên suốt toàn bộ pipeline để đảm bảo tính tái lập. Mục tiêu dự báo là phân loại nhị phân (Safe và Not Safe) nhằm ưu tiên phát hiện sớm nhóm sinh viên có nguy cơ (Fail/Withdrawn). Do đó, các độ đo **Recall (Not Safe)** và **Macro-F1** được sử dụng làm metric chính.

2.2 Tiền xử lý dữ liệu và làm sạch

Dựa trên phân tích ngữ nghĩa, các bước sau được thực hiện để xử lý dữ liệu khuyết:

- `date_registration`: Điền các giá trị thiếu bằng giá trị trung vị (median) của đợt học tương ứng.
- `imd_band`: Chuyển đổi các giá trị null thành nhãn “Unknown” (được gán giá trị 10, nằm ở cuối thang đo).
- `score`: Điền giá trị 0 cho các bài đánh giá không có điểm (tương đương với việc không nộp bài).
- **Loại bỏ các trường dữ liệu nhiễu**: Xóa bỏ cột `week_from`, `week_to` do tỷ lệ trống quá cao, và đặc biệt loại bỏ `date_unregistration` nhằm ngăn chặn tình trạng rò rỉ dữ liệu (data leakage).

2.3 Nhóm đặc trưng tương tác trước khóa học

Để đo lường mức độ chuẩn bị của người học trước ngày khai giảng ($ngy < 0$), nhóm trích xuất các đặc trưng sau:

- `pre_course_clicks`: Tổng lượng tương tác của người học trên hệ thống trước ngày 0.
- `pre_course_active_days`: Số ngày người học có truy cập hệ thống trước ngày 0.
- `has_pre_course_activity`: Biến nhị phân xác định người học có hoạt động chuẩn bị sớm hay không.

2.4 Nhóm đặc trưng tương tác hệ thống (VLE)

Nhóm tập trung vào các hành vi tương tác biến thiên tính đến ngày 135:

- `last_active_day`: Ngày tương tác cuối cùng trên hệ thống (đây là chỉ số quan trọng nhất để nhận diện nhóm Withdrawn).

- `std_clicks`: Độ lệch chuẩn của lượng click hàng ngày, nhằm đo lường tính kỷ luật và sự đều đặn trong quá trình học.
- `active_days`: Tổng số ngày thực tế mà người học có tương tác với hệ thống.
- **Lượt tương tác hàng tuần (Weekly Clicks)**: Dữ liệu click được tổng hợp thành 20 biến (từ `clicks_week_1` đến `clicks_week_20`) tương ứng với 135/7 tuần. Các tuần không có hoạt động được điền giá trị 0.
- **Phân loại tài nguyên (Activity Breakdown)**: Lượng tương tác được chia theo các nhóm tài nguyên quan trọng: `clicks_content` (nội dung bài học chính), `clicks_forum` (tương tác diễn đàn - thường có tương quan cao với kết quả Pass), và `clicks_quiz`, `clicks_resource` (các tín hiệu hỗ trợ).

2.5 Nhóm đặc trưng đánh giá học tập

Chỉ các bài đánh giá có `deadline ≤ 135` (Safe Assessment) mới được sử dụng. Toàn bộ các bài thi cuối kỳ (Exam) bị loại bỏ vì gây rò rỉ dữ liệu tuyệt đối.

- `weighted_score_before_cutoff`: Điểm tích lũy có trọng số trước ngày cắt, tính theo công thức $\frac{\sum(\text{score} \times \text{weight})}{\sum \text{weight}}$.
- `tma_submission_rate` và `cma_submission_rate`: Tỷ lệ nộp bài, tính bằng công thức $\frac{n_{\text{submitted}}}{n_{\text{safe_in_module}}}$. Nếu học phần không có loại bài này trước ngày 135, giá trị được điền là -1. Nếu có bài nhưng người học không nộp, giá trị là 0.
- `avg_days_before_deadline`: Trung bình số ngày nộp bài trước hạn. Trễ hạn sẽ có giá trị âm.
- `n_missing_submission`: Tổng số bài đánh giá “Safe” mà người học bỏ lỡ.
- **Xử lý ngoại lệ (Edge Cases)**: Học phần **GGG** có trọng số TMA bằng 0 nên không thể tính điểm tích lũy. Nhóm tạo thêm cột `has_weighted_score = 0` và dùng `TMA submission count` để thay thế. Đối với học phần **AAA** và **EEE**, do không có bài CMA trước ngày 135, `cma_submission_rate` được gán giá trị -1.

2.6 Nhóm đặc trưng nhân khẩu học

- `module_semester`: Kết hợp mã học phần và học kỳ (ví dụ: AAA_B) và sử dụng phương pháp mã hóa nhãn (*Label Encoding*).
- `num_of_prev_attempts`: Được giữ nguyên vì có tương quan mạnh với rủi ro trượt hoặc rút môn.
- **Mã hóa thứ tự (Ordinal Encoding)**:
 - `highest_education`: Sắp xếp theo trình độ từ thấp đến cao.

- age_band: $0 - 35 < 35 - 55 < 55+$.
 - imd_band: $0 - 10\% < \dots < 90 - 100\% < \text{Unknown}$.
- Đặc trưng gender bị loại bỏ vì đóng góp rất yếu vào khả năng dự báo.

2.7 Chiến lược phân chia dữ liệu và chuẩn hóa

Nhóm thiết lập quy trình chuẩn bị dữ liệu huấn luyện nghiêm ngặt nhằm tránh rò rỉ:

- **Phân tầng (*Stratified Split*)**: Tập dữ liệu được phân chia dựa trên nhãn mục tiêu và mã học phần nhằm đảm bảo sự phân bố đồng đều giữa các tập.
- **Chia theo cấp độ người học (*Student-level Split*)**: Đảm bảo tất cả các bản ghi thuộc về cùng một `id_student` phải nằm hoàn toàn trong tập Train hoặc tập Test. Điều này ngăn chặn việc mô hình “ghi nhớ” hành vi của cùng một người học ở các học phần khác nhau.
- **Chuẩn hóa (*Scaling*)**: Đối với các mô hình cây quyết định (Random Forest, XGBoost), dữ liệu không cần chuẩn hóa. Khi sử dụng các mô hình tuyến tính, phương pháp `StandardScaler` được áp dụng, trong đó chỉ gọi hàm `fit` trên tập Train và `transform` cho tập Test để tránh rò rỉ dữ liệu thống kê.

Tài liệu

- [1] John Doe. Dummy reference, 2026. This is a dummy reference to satisfy BibTeX.