

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN CUỐI KỲ
CS313 - KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

HỆ THỐNG CẢNH BÁO SỚM
KẾT QUẢ HỌC TẬP SINH VIÊN
TRÊN BỘ DỮ LIỆU OULAD

Giảng viên hướng dẫn:

TS. Võ Nguyễn Lê Duy

Nhóm 11:

Họ tên	MSSV
Nguyễn Đặng Ân Phước	24521408
Phạm Quang Hữu Phước	24521411
Văn Đức Tân	24521586
Liên Phúc Thịnh	24521686
Lê Như Thực	24521747

Thành phố Hồ Chí Minh, Tháng 5/2026

Mục lục

1 Khám phá dữ liệu	1
1.1 Tổng quan dataset và phân phối biến mục tiêu	1
1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu	1
1.3 Phân tích tín hiệu feature	3
1.4 Kết luận EDA	3
2 Kỹ thuật đặc trưng (Feature Engineering)	4
2.1 Thiết lập chung và Tiền xử lý dữ liệu	4
2.2 Nhóm đặc trưng tĩnh (Static Features)	4
2.3 Nhóm đặc trưng động nhân quả (Causal Dynamic Features)	4
2.4 OOT Split, Features Encoding và Chuẩn hóa	5
2.5 Phân tích tương quan và Lọc bỏ đặc trưng (Feature Selection)	6
2.6 Các định dạng dữ liệu đầu ra phục vụ huấn luyện	6
3 Mô hình hóa (Modeling)	7
3.1 Phạm vi thử nghiệm	7
3.2 Mô hình XGBoost và LightGBM	7
3.3 Mô hình LSTM và Transformer	8
3.4 Kết luận	8

1 Khám phá dữ liệu

1.1 Tổng quan dataset và phân phối biến mục tiêu

OULAD là bộ dữ liệu học tập liên kết gồm 7 bảng quan hệ, bao gồm thông tin của 32.593 lượt đăng ký môn học và hơn 10,6 triệu lượt tương tác trên môi trường học tập ảo (VLE). Biến mục tiêu thể hiện kết quả học tập của người học được chia thành 4 loại `final_result` $\in \{\text{Pass, Withdrawn, Fail, Distinction}\}$.

File	Dòng	Cột có null (%)
studentInfo	32.593	imd_band 3,4%
studentRegistration	32.593	date_unreg 69,1%
studentAssessment	173.912	score 0,1%
studentVle	10.655.280	—
assessments	206	date 5,3%
courses	22	—
vle	6.364	week_from/to 82,4%

Nhãn	Số lượng	Tỉ lệ
Pass	12.361	37,93%
Withdrawn	10.156	31,16%
Fail	7.052	21,64%
Distinction	3.024	9,28%

Trong phạm vi đề án này, nhóm thực hiện chuyển đổi bài toán về dạng **phân loại nhị phân** bằng cách gộp các nhãn mục tiêu ban đầu thành hai nhóm chính:

- **NOT AT-RISK**: Gồm các người học đạt kết quả *Pass* hoặc *Distinction* (nhóm người học an toàn).
- **AT-RISK**: Gồm các người học rơi vào trạng thái *Fail* hoặc *Withdrawn* (nhóm người học gặp rủi ro học tập).

Sau khi chuyển đổi, tỷ lệ giữa nhóm NOT AT-RISK ($\sim 47,2\%$) và AT-RISK ($\sim 52,8\%$) tương đối cân bằng. Tuy nhiên, nhóm vẫn chọn **F1** làm độ đo đánh giá chính nhằm đảm bảo mô hình có khả năng phân loại tốt và công bằng trên cả hai nhóm. Điều này giúp tránh tình trạng mô hình dự đoán thiên lệch, từ đó đảm bảo hệ thống cảnh báo sớm đưa ra các quyết định can thiệp đáng tin cậy.

1.2 Phân tích null ngữ nghĩa và kiểm toán rò rỉ dữ liệu

1.2.1 Phân tích toán tử khuyết mang ngữ nghĩa

Đối với bộ dữ liệu OULAD, các giá trị rỗng không đơn thuần biểu thị sự thiếu hụt dữ liệu, mà ngược lại, mỗi vị trí null đều mang một ngữ nghĩa cụ thể:

Cột	Null %	Ý nghĩa thực	Quyết định
date_unregistration	69,1%	Học đến hết module	Drop (leakage 99,1% Withdrawn)
score	0,1%	Bài không nộp	fillna(0)
imd_band	3,4%	Địa chỉ ngoài UK	Encode "Unknown"
week_from / week_to	82,4%	Resource trải toàn module	Drop cả 2 cột

Lưu ý hai con số dễ gây nhầm: **69,1%** là tỷ lệ null trên *toàn bộ* dữ liệu, còn **99,1%** là tỷ lệ người học *Withdrawn* có ghi nhận ngày rút môn. Nói cách khác, gần như chỉ nhóm *Withdrawn* mới có giá trị này, biến nó thành biến đại diện cho nhãn mục tiêu. Do thông tin chỉ phát sinh sau khi người học rút môn, giữ lại sẽ gây rò rỉ dữ liệu; vì vậy nhóm loại bỏ đặc trưng này.

1.2.2 Chọn cut-off theo data

Median module length 262 ngày. Phân tích phân phối ngày rút môn trên $n = 10.156$ *Withdrawn*: day 135 capture 80,4% *Withdrawn*; day 170 capture 89,3% và còn 92 ngày (35,1% thời gian module) để can thiệp. Nhóm chọn **cut-off = 170** làm mốc cắt dữ liệu cho Feature Engineering, tương ứng **25 tuần** học ($T_{\max} = \lceil 170/7 \rceil$).

Hai hướng tiếp cận mô hình sử dụng chung dữ liệu FE này:

- **Mô hình cây (XGBoost, LightGBM)**: Dự đoán tại các mốc tuần $\{4, 8, 12, 16, 20, 24\}$. Tại mỗi mốc tuần t , mô hình chỉ nhìn dữ liệu từ ngày 0 đến ngày $7(t+1) - 1$, đảm bảo không rò rỉ thông tin từ tương lai.
- **Mô hình chuỗi (LSTM, Transformer)**: Nhận toàn bộ chuỗi 25 tuần dưới dạng panel. Tại mỗi tuần t , mô hình chỉ quan sát dữ liệu đến tuần t nhờ cơ chế che nhân quả, cho phép dự đoán liên tục mà không cần mốc cắt cố định.

1.2.3 Kiểm toán rò rỉ dữ liệu

Toàn bộ 206 bài đánh giá phân loại NOT AT-RISK ($\text{deadline} \leq 170$) vs AT-RISK ($\text{deadline} > 170$):

Loại	NOT AT-RISK	AT-RISK	Median submit ratio	Quyết định
TMA	89	17	0,349	Dùng (đa số NOT AT-RISK)
CMA	24	52	0,561	Chuẩn hóa theo từng module
Exam	0	13	0,927	Drop hoàn toàn

Median submit ratio Exam (0,927) $\Rightarrow$ bài thi luôn ở cuối kỳ, không có bài NOT AT-RISK nào tại day 170, drop. CMA có 24/76 NOT AT-RISK phân bố không đều giữa modules (FFF, GGG không có CMA NOT AT-RISK trước day 170) $\Rightarrow$ FE chuẩn hoá thành `cma_submission_rate`.

1.3 Phân tích tín hiệu feature

1.3.1 Tín hiệu nhân khẩu học

Chi-square test ($n = 32.593$) trên các biến categorical so với nhãn `final_result`:

Feature	χ^2	Signal
code_module	1443,2	Rất mạnh
highest_education	1024,7	Rất mạnh
imd_band	666,9	Rất mạnh
region	449,7	Mạnh
age_band	222,7	Mạnh

Các biến trong bảng đều đạt ý nghĩa thống kê và được encode ordinal để bảo toàn quan hệ monotonic cho tree-based model.

Riêng gender ($\chi^2 = 16,5$) và disability ($\chi^2 = 138,5$) tuy vẫn có tín hiệu thống kê nhưng được loại bỏ vì lý do đạo đức: đây là các thuộc tính nhạy cảm, dùng làm yếu tố dự báo kết quả học tập có thể dẫn đến phân biệt đối xử và thiếu công bằng với người học. Do đó mô hình chỉ giữ 4 biến nhân khẩu học còn lại.

1.3.2 Hiệu ứng kỳ học (kỳ B và kỳ J)

Pass rate kỳ B (tháng 2) = 43,67% ($n = 12.488$), kỳ J (tháng 10) = 49,40% ($n = 20.105$). Chênh lệch không đồng đều theo module: CCC diff = -6,38 pp, EEE diff = -6,28 pp, đều vượt ngưỡng ± 5 pp $\Rightarrow$ semester **phải là feature**, không lọc bỏ. Trong đó **pp** (*percentage point*) là hiệu trực tiếp giữa hai tỷ lệ phần trăm, ví dụ $49,40\% - 43,67\% = 5,73$ pp.

1.4 Kết luận EDA

EDA xác định các nhóm tín hiệu khả dụng tại cut-off 170: (i) nhân khẩu học (4 biến mạnh sau chi-square), (ii) điểm có trọng số trước cut-off (TMA NOT AT-RISK 89/106), (iii) hành vi nộp bài (submission rate, deadline gap). Tín hiệu hành vi VLE sẽ phân tích chi tiết ở giai đoạn Feature Engineering sau khi thống nhất pipeline nhị phân (AT-RISK vs NOT AT-RISK).

2 Kỹ thuật đặc trưng (Feature Engineering)

2.1 Thiết lập chung và Tiền xử lý dữ liệu

Dữ liệu được tái cấu trúc thành dạng chuỗi tuần (*weekly panel*) cho mô hình LSTM và Transformer với các thiết lập:

- **Mốc cắt (*Cut-off Day*):** Ngày **170** của học kỳ, tương ứng tối đa **25 tuần** học ($T_{MAX} = 25$, độ dài tuần 7 ngày). Các tương tác và điểm số sau ngày 170 bị loại bỏ.
- **Nhãn mục tiêu:**
 - At Risk (Fail/Withdrawn): Gán 1.
 - Not At Risk (Pass/Distinction): Gán 0.

Quy trình làm sạch dữ liệu thô bao gồm:

- `date_registration`: Trung vị theo đợt học (*module-presentation*).
- `imd_band`, `age_band`: “Unknown”.
- `score` (khuyết): 0.
- `date_unregistration`, `week_from`, `week_to`: Loại bỏ hoàn toàn.

2.2 Nhóm đặc trưng tĩnh (Static Features)

Đặc trưng tĩnh là thông tin cố định, được truyền vào mô hình tại mọi bước thời gian:

- **Nhân khẩu học:** `gender`, `age_band`, `imd_band`, `region`, `highest_education`, `disability`, `studied_credits` và `num_of_prev_attempts`.
- **Bối cảnh học tập:** `date_registration`, `code_module`, `code_presentation`, `module_semester` và `semester`.
- **Tương tác trước khóa học** ($date < 0$): `pre_course_clicks`, `pre_course_active_days` và `has_pre_course_activity`.

2.3 Nhóm đặc trưng động nhân quả (Causal Dynamic Features)

Đặc trưng tại tuần t chỉ được tổng hợp từ dữ liệu phát sinh từ ngày 0 đến $7(t+1) - 1$ để đảm bảo tính nhân quả. Bao gồm ba nhóm:

1. Tương tác VLE tích lũy:

- `clicks_this_week`: Tổng click trong tuần t .
- `cum_active_days`: Số ngày tương tác tích lũy.
- `clicks_per_active_day_cum`: Click trung bình mỗi ngày hoạt động.
- `days_since_last_active`: Số ngày kể từ lần tương tác cuối.

2. Xu hướng tương tác và khoảng trống:

- `click_slope_recent`, `click_slope_r2_recent`: Hệ số góc và hệ số xác định hồi quy click trên 4 tuần gần nhất $[t - 3, t]$.
- `activity_density_so_far`: Mật độ ngày hoạt động tích lũy.
- `gap_trend_so_far`: Xu hướng khoảng cách giữa các ngày hoạt động liên tiếp.
- `weekend_ratio_so_far`: Tỷ lệ click vào cuối tuần.
- `ratio_{type}_so_far`: Tỷ lệ click theo từng loại tài nguyên (oucontent, forumng, homepage, quiz).

3. Kết quả học tập tích lũy:

- `mean_score_so_far`: Điểm trung bình tích lũy.
- `weighted_score_so_far`, `has_weighted_score_so_far`: Điểm trọng số tích lũy và cờ xác nhận đã có ít nhất một bài được chấm điểm có trọng số.
- `avg_days_before_deadline_so_far`: Số ngày nộp trước hạn trung bình.
- `tma_submission_rate_so_far`, `cma_submission_rate_so_far`: Tỷ lệ nộp bài TMA và CMA.
- `cum_n_submitted`: Tổng số bài đánh giá đã nộp.

2.4 OOT Split, Features Encoding và Chuẩn hóa

Chiến lược phân chia Out-of-Time (OOT) theo kỳ học thực tế được thực hiện trước tiên để tránh rò rỉ thông tin:

- **Tập Train (21.333 lượt học)**: Gồm dữ liệu sinh viên thuộc các kỳ học cũ (2013B, 2013J, 2014B).
- **Tập Test (11.260 lượt học)**: Gồm dữ liệu sinh viên thuộc kỳ học cuối cùng (2014J).

Sau khi phân chia, toàn bộ encoder và scaler đều được fit chỉ trên tập Train rồi transform sang tập Test. Phương pháp mã hóa gồm:

- **Ordinal Encoding**: Áp dụng cho các biến thứ bậc gồm `highest_education_encoded`, `age_band_encoded` và `imd_band_encoded`.
- **Binary Encoding**: Dành cho `semester_enc`, `gender_encoded`, `disability_encoded` và đợt học `module_semester_encoded`.
- **One-hot Encoding**: Chuyển đổi vùng địa lý `region` thành 12 biến giả nhị phân.

Các đặc trưng số tiếp theo được chuẩn hóa bằng `StandardScaler` (fit trên Train, transform trên cả Train và Test).

2.5 Phân tích tương quan và Lọc bỏ đặc trưng (Feature Selection)

Quy trình lọc bỏ đặc trưng:

- **Loại bỏ vì lý do đạo đức (Fairness):** Loại bỏ `gender_encoded` và `disability_encoded` để tránh phân biệt đối xử trong dự đoán.
- **Kiểm định tương quan Pearson:** Tính toán tương quan giữa từng đặc trưng số động với nhãn mục tiêu tại tuần cuối cùng ($T = 24$), giữ lại các đặc trưng có $|corr| \geq 0,05$.
- **Kiểm định Chi-square (χ^2):** Loại bỏ các đặc trưng có mức ý nghĩa p -value $> 0,05$.

Kết quả của quá trình lọc chọn đặc trưng:

- **Dynamic Features:** Loại bỏ **5 đặc trưng**: `ratio_subpage_so_far`, `n_submitted_week`, `ratio_url_so_far`, `gap_std_so_far`, `weekend_clicks_week`.
- **Static Features:** Loại bỏ **3 đặc trưng**: 3 biến giả khu vực địa lý (`region_Scotland` ($p = 0.76$), `region_East_Midlands_Region` ($p = 0.16$), `region_Wales` ($p = 0.06$)).

Mô hình LSTM và Transformer cuối cùng sẽ chỉ tiếp nhận chuỗi Tensor `X_seq` gồm 20 đặc trưng động và Tensor tĩnh `X_static` gồm 20 đặc trưng tĩnh đã được tinh lọc.

2.6 Các định dạng dữ liệu đầu ra phục vụ huấn luyện

Tập dữ liệu sau khi tinh lọc còn lại **20 đặc trưng động** và **20 đặc trưng tĩnh** được kết xuất thành ba định dạng cấu trúc khác nhau để phục vụ song song cho các pha huấn luyện mô hình:

- **LONG Format** (`df_train_long.csv`, `df_test_long.csv`): Dạng bảng tuần (*panel data*, 25 dòng/lượt học) cho LSTM và Transformer.
- **WIDE Format** (`df_train.csv`, `df_test.csv`): Dạng phẳng (snapshot tại tuần học cuối $T \in \{4, 8, 12, 16, 20, 24\}$) cho XGBoost và LightGBM.
- **TENSOR Format** (các file `.npy`): Các mảng numpy 3D/2D đã chuẩn hóa để nạp trực tiếp vào PyTorch.

3 Mô hình hóa (Modeling)

3.1 Phạm vi thử nghiệm

Phần modeling trong đề án được thực hiện trên hai nhánh khác nhau: nhánh mô hình học máy truyền thống và nhánh mô hình chuỗi. Các mô hình được đánh giá theo nhiều mốc thời gian để phản ánh đúng bài toán cảnh báo sớm. Với nhánh ML, nhóm sử dụng các snapshot tuần 4, 8, 12, 16, 20 và 24. Với nhánh sequence, mô hình được đánh giá liên tục theo từng tuần, từ giai đoạn đầu khóa học đến cuối khóa học. Các metric chính gồm AUC-ROC, Accuracy, Precision, Recall và F1-score.

3.2 Mô hình XGBoost và LightGBM

Trong nhánh ML truyền thống, nhóm huấn luyện hai mô hình tree boosting là **XGBoost** và **LightGBM** cho từng snapshot tuần. Mỗi snapshot chỉ sử dụng thông tin đã có tới thời điểm tương ứng, nhờ đó mô phỏng được tình huống hệ thống cảnh báo được cập nhật định kỳ trong quá trình học.

Kết quả LightGBM

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8221	0,7397	0,7428	0,7570	0,7499
8	0,8738	0,7811	0,8583	0,6890	0,7644
12	0,8870	0,7981	0,8135	0,7892	0,8012
16	0,9263	0,8518	0,9169	0,7834	0,8449
20	0,9441	0,8774	0,9200	0,8347	0,8753
24	0,9626	0,9015	0,9372	0,8670	0,9007

Kết quả XGBoost

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8266	0,7263	0,6948	0,8363	0,7590
8	0,8775	0,7829	0,8592	0,6921	0,7666
12	0,8826	0,7893	0,7934	0,7994	0,7964
16	0,9295	0,8485	0,9211	0,7722	0,8401
20	0,9454	0,8778	0,9259	0,8292	0,8749
24	0,9624	0,9012	0,9391	0,8642	0,9001

Kết quả cho thấy cả hai mô hình đều cải thiện rõ khi có thêm dữ liệu theo thời gian. Ở tuần 4, mô hình đã đạt F1 khoảng 0,75, cho thấy các tín hiệu ban đầu đủ mạnh để phát cảnh báo sớm. Đến tuần 24, F1 đạt khoảng 0,90 và AUC vượt 0,96.

3.3 Mô hình LSTM và Transformer

Nhánh sequence sử dụng dữ liệu dạng chuỗi theo tuần để huấn luyện mô hình **LSTM** và **Transformer**. Mô hình nhận hai nhóm đầu vào: đặc trưng động theo thời gian và đặc trưng tĩnh của sinh viên.

Kết quả LSTM

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8147	0,7352	0,8106	0,6343	0,7117
8	0,8790	0,7884	0,8864	0,6760	0,7670
12	0,8969	0,8171	0,8866	0,7398	0,8066
16	0,9311	0,8571	0,9338	0,7779	0,8487
20	0,9472	0,8800	0,9616	0,7991	0,8728
24	0,9639	0,9023	0,9659	0,8401	0,8986
33	0,9808	0,9329	0,9752	0,8926	0,9321

Kết quả Transformer

Tuần	AUC	Accuracy	Precision	Recall	F1
4	0,8277	0,7481	0,7805	0,7114	0,7443
8	0,8791	0,7923	0,8663	0,7058	0,7779
12	0,8963	0,8099	0,8490	0,7675	0,8062
16	0,9288	0,8552	0,8867	0,8244	0,8544
20	0,9430	0,8763	0,9214	0,8308	0,8738
24	0,9629	0,8996	0,9202	0,8818	0,9006
33	0,9775	0,9295	0,9742	0,8866	0,9284

LSTM và Transformer thể hiện xu hướng tăng ổn định theo số tuần quan sát. Ở tuần 12, F1 đạt 0,8; đến tuần 24 đạt 0,9; và ở tuần 33 đạt 0,93. Điều này cho thấy mô hình khai thác tốt thông tin tích lũy dài hạn trong chuỗi hành vi học tập.

3.4 Kết luận

Ở các tuần 20–24, cả mô hình ML theo snapshot và mô hình sequence đều đạt F1 xấp xỉ 0,87–0,90, cho thấy hệ thống đã có thể đưa ra cảnh báo tương đối tin cậy trước khi kết thúc khóa học.